

バイラテラル制御に基づく模倣学習による 三次元曲面拭き動作の学習

山根 広暉^{*1} 七種 勇樹^{*1} 境野 翔^{*1} 辻 俊明^{*2}

3D Surface Wiping using Bilateral Control-Based Imitation Learning

Koki Yamane^{*1}, Yuki Saigusa^{*1}, Sho Sakaino^{*1} and Toshiaki Tsuji^{*2}

Wiping the surface of an object with a robot is necessary to automate various tasks such as cleaning and polishing. However, it is very difficult to move contact points while maintaining the appropriate force with position control. It is because the force response when contact with the object varies greatly with slight differences in the positional relationship, it is greatly affected by errors in the shape measurement and positional errors in the robot's motion. To achieve this, force control that directly handles the force response is necessary. In this study, we used bilateral control-based imitation learning to learn wiping motions for several types of bowls as objects with various 3D curved surface shapes, and verified their performance.

Key Words: Imitation Learning, Bilateral Control, Machine Learning, Motion Control, Wiping

1. 序 論

ロボットで物体の面を拭く動作は、清掃や研磨など様々なタスクをロボットで自動化するために必要となるが、事前に決められた軌道を位置制御で追従する従来のロボットでは、適切な力加減を維持しながら接触点を移動させることは非常に困難である。外界センサで事前に対象物体の形状を計測し位置制御をベースとした動作計画を行うことが考えられるが、対象物体と接触した際の力加減はわずかな位置関係の違いで大きく変化するため、観測の誤差やロボットの動作の位置誤差の影響を大きく受けてしまい、事前に計画した位置制御を行うだけでは力加減を考慮した動作は難しい。これを実現するためには、力加減を直接指定して制御する力制御が必要となる。また、事前に正確に形状が分かっているケースや環境が変化するケースを考慮する場合、あらかじめ時間に応じた軌道を決めておくのではなく、動作中に逐次的に次の動作を決定しながらタスクを行う必要がある。

逐次的に動作を決定する動作生成手法として、機械学習を用いてデータから学習した方策を用いる手法が知られている。なかでも、人間の操作データを用いた教師あり学習によって人間を模倣した方策を得る模倣学習 [1] [2] は、成功した動作のデータから学習するためサンプル効率がよく、データの収集ができればプログラムの変更などせずにタスクを追加できるなどのメリットがあり、様々なタスクでその有効性が示されている。Kormushev らは力と位置の情報を統合した模倣学習を行い、ドアの開閉タ

スクを実現している [3]。しかし、対象物の情報を画像等で取得していないので、位置の変動があった場合などに生じる力の誤差は補償しきれない。また、Saito らは、画像、触覚、関節角の情報を用いた模倣学習により、対象物体のモデルを用いずに物体を拭くタスクを実現している [4]。しかし、制御に用いる指令値には関節角の角度のみが用いられており、物体と接触した際の力加減を指令値として制御する力制御は用いられていない。このため、ロボットの位置制御の誤差などで力加減が目標と異なってしまう可能性がある。Wang らは、動作の大まかな軌道を模倣学習で獲得し、細かい力加減を強化学習により獲得することで、力制御による組み立てタスクを実現している [5]。しかし、大まかな軌道を得る模倣学習には力情報は入っていないため、力情報に応じて大幅に動作を変化させることはできず、位置や形状の違いに対応することは困難である。

これに対し、力の指令値を予測し力制御を行う模倣学習として、遠隔操作技術であるバイラテラル制御を用いた、バイラテラル制御に基づく模倣学習が提案されている [6] [7]。バイラテラル制御に基づく模倣学習は、力加減が重要な様々なタスクに対して有効性が示されており、また、人間と同程度の高速な動作を学習することが可能である。しかし、オブジェクトの曲面形状や位置が異なるケースに対応する必要があるタスクに対しては実証がなされていない。

本研究では、バイラテラル制御に基づく模倣学習を用いて、位置の異なる複数種類のボウルを対象とした拭き動作を学習し、様々な三次元曲面形状を持つ物体に対応する性能を検証した。

2. 関 連 研 究

2.1 模倣学習

模倣学習は、状態と行動の組の時系列データとして表現された人間の操作データを用いて、現在の状態を入力、次のステップ

原稿受付 2022 年 7 月 11 日

^{*1}筑波大学

^{*2}埼玉大学

^{*1}University of Tsukuba

^{*2}Saitama University

■ 本論文は有用性（要素分野）で評価されました。




Fig. 1 Model overview



Fig. 2 Experimental environment

の行動を出力として教師あり学習を行う手法である。人間が操作して成功したデータを用いて学習を行うため、機械学習を用いたロボットの制御手法の中でもサンプル効率が高い手法である。また、データから必要な出力を直接学習する End-to-End Learning の手法であり、人間が直接動作を指定することが難しい複雑なタスクでも簡単に扱うことが可能となっている。

2.2 バイラテラル制御に基づく模倣学習

バイラテラル制御に基づく模倣学習 [6] [7] は、力制御を用いた遠隔操作技術である 4ch バイラテラル制御を用いて収集したデータを模倣学習の教師データとして用いる手法である。

模倣学習の教師データの収集には、人間が直接ロボットを動かすダイレクトティーチング [3] が広く用いられている。しかし、人間が直接ロボットに力を加える場合、ロボットには人間が加えた力と環境との接触による反力が同時に加わるため、これらを別々に計測することはできない。

一方、バイラテラル制御は 2 台のロボットを用いて遠隔操作を行う技術であり、人間が力を加える側のロボットと環境からの反力を受ける側のロボットを分けることができる。これにより、環境からどれだけ反力を受け、それに対し人間がどれだけの力を加えたかという情報を得ることができる。この情報を模倣学習に用いることで、人間の力加減を模倣することが可能となる。

また、従来の模倣学習は、現在のステップの応答値から次のステップの応答値を予測してそれを指令値とするが、ロボットには制御遅れがあるため応答値と指令値は一致しない。この差を無視できる程度の速度で動作させる必要があるため、人間と比較して非常に低速な動作となってしまう。これに対し、バイラテラル制御に基づく模倣学習は、自律動作をするロボットの応答値から次の指令値を予測し、その指令値をロボットに与える。このため、制御遅れを考慮した学習が可能であり、高速な自律動作を実現することができる。

3. ロボットシステム

3.1 ハードウェア

本研究の実験には RT 社製のマニピュレータである CRANE-X7 に独自に開発したハンドを取り付けたものを用いた。マニピュレータの自由度は 7 自由度、グリップの自由度は 1 自由度

であり、全体として 8 自由度のロボットを使用した。

3.2 制御システム

位置と力のハイブリッド制御により各軸の制御器を構成した。位置に対しては PD 制御、力に対しては P 制御を適用した。制御周期は 500 [Hz] とした。

各関節の角度はロータリーエンコーダより取得し、その微分により角速度を算出した。また、この制御には各軸の反力トルクの観測が必要だが、本研究で使用了 CRANE-X7 はトルクセンサが搭載されていない。このため、外乱トルク τ^{dis} は外乱オブザーバ (DOB) [8] を用いて算出し、トルク応答値 τ^{res} は反力推定オブザーバ (RFOB) [9] により推定した。トルク参照値は以下のように算出される。

$$\tau^{ref} = -\frac{J}{2}(K_p + K_d s)(\theta^{res} - \theta^{cmd}) - \frac{1}{2}K_f(\tau^{res} - \tau^{cmd}) \quad (1)$$

J は関節の慣性モーメント、 K_p, K_d, K_f はそれぞれ位置制御、速度制御、力制御の制御ゲインである。

3.2.1 4ch 型バイラテラル制御

模倣学習に使用する人間の操作データを収集するために、遠隔操作技術である 4ch 型バイラテラル制御を使用した。4ch 型バイラテラル制御は、人間が直接操作するリーダーと、リーダーに追従して動作するフォロワの 2 台のロボットからなる。位置とトルクの二つを同時に制御するシステムであり、位置に関しては、リーダーにはフォロワの関節角、フォロワにはリーダーの関節角をそれぞれ目標値とすることで互いの関節角が一致するように制御する。トルクに関しては、リーダーの関節にかかるトルクの符号を逆にしたものが人間が与えているトルクであり、また、フォロワの関節にかかるトルクの符号を逆にしたものがフォロワが環境から受けた反力である。このため、関節トルクの符号を反転したものを互いにトルク目標値とすることで、フォロワが人間の力加減を再現し、リーダーがフォロワの反力を再現するような制御を実現する。4ch 型バイラテラル制御における角度とトルクの目標値は以下のように定義される。

$$\theta_l^{res} = \theta_f^{res} \quad (2)$$

$$\tau_l^{res} = -\tau_f^{res} \quad (3)$$

ここで、 θ は関節角ベクトル、 τ は関節トルクベクトル、添




Fig. 3 Task flow



Fig. 4 Used bowls




Fig. 5 Position of bowl




Fig. 6 Position estimation

字 l と f はそれぞれリーダとフォロウを表す。

4. 三次元曲面拭き動作の学習

4.1 タスク設定

本研究では、ボウルの内側を拭くタスクを行った。使用した実験環境を Fig. 2 に示す。人間が抑えて固定した状態のボウルを下側から縁近くへ円周にそって拭いていき、最後に底の部分を拭いて終了する。タスクの一連の流れを Fig. 3 に示す。学習用のボウルは金属、プラスチック、木製の 3 種類を用意した。それぞれ Bowl1, Bowl2, Bowl3 とする。また、学習に用いないテスト用のボウルを 3 種類用意した。それぞれ Bowl4, Bowl5, Bowl6 とする。使用したボウルを Fig. 4 に示す。各ボウルは素材だけでなく、大きさや曲率などの形状が異なる。ボウルの種類は既知とし、人間がロボットにラベルを入力する。また、ボウルの位置は可変とし、深度画像情報を用いた物体検出を行って位置を取得する。RGB-D カメラは Intel RealSense D415 を使用した。

4.2 学習モデル

模倣学習では、ニューラルネットワークモデルに現在の状態を入力し、次のステップの指令値を予測する。バイラテラル制御に基づく模倣学習では、現在の状態や指令値としてロボットの各関節の角度、角速度、トルクを用いる。使用したニューラルネットワークモデルの全体像を Fig. 1 に示す。図の f はフォロウの各関節の角度、角速度、トルク、 l はリーダの各関節の角度、角速度、トルクをまとめたベクトルを表す。ボウルを拭くタスクは単純に平面を繰り返し拭くといった周期動作と異なり、どこまで拭いたかを常に記憶してそれに基づいて動作する必要がある。このため、学習モデルの長期記憶能力が重要になると考えられる。そこで、本研究では、バイラテラル制御に基づく模倣学習の手法の中で、長期記憶能力が高い階層化モデル [10] を利用した。階層化モデルは、上位層と下位層の二つの Long Short-Term Memory (LSTM) [11] を用い、上位層は長い周期で動作し、下位層は短い周期で動作することで、上位層が長い

期間を俯瞰した記憶を持ち、下位層が細かい動作の補完を行うとするモデルである。階層化を行わないモデルと比較して、上位層の時間間隔が長いので、LSTM の記憶できるステップ数に対して対応する実時間が長くなり、記憶できる期間が長くなる効果が見込める。上位層の入力としては、フォロウの応答値のほかに、対象のボウルの種類を表す one-hot vector とボウルの位置の座標を入力することで、ボウルの種類と位置の違いに対応した学習を可能とした。下位層には自己回帰学習が可能な F2FL モデル [10] を使用した。

4.3 データセット

縦横 3×3 の九つの位置で 3 種類のボウルに対してそれぞれ 1 回のタスクを行い、合計 27 回のタスクのデータを収集した。実験に用いた配置を Fig. 5 に示す。

これに加え、一度学習したモデルで自律動作させたときのデータを蓄積し、成功したデータを学習データに加えてさらに学習する自己学習を行った。データ収集と同じ条件でそれぞれ各 5 回のデータを追加し、合計 162 回のデータで学習を行った。

本研究では、500 [Hz] で取得したデータに対し、10 ステップごとにサンプリングして 50 [Hz] になるようにデシメーションを行った。これは、時系列データでニューラルネットワークを学習する場合、ある程度サンプリング周波数を落とすことで学習効率を上げることができるとある [12]。また、データ数を擬似的に 10 倍に増やすことができるほか、ローパスフィルタと組み合わせることでデータから模倣する必要のない高周波成分を排除し、動作の安定性を高めることができる。

4.4 位置検出

ボウルの位置の違いに対応した動作生成を行うためには、ニューラルネットワークにボウルの位置を入力する必要がある。そこで、本研究では、画像からの物体検出によりボウルの位置を取得した。今回使用するオブジェクトは円形のボウルに限定されているため、depth 画像に対して Hough 変換による円検出を行い、検出された円の中心座標をニューラルネットワークに入力した。実際に円検出を行った結果を Fig. 6 に示す。図の円

Table 1 Success rate

			x		
			1	2	3
Bowl 3	y	1	80.0 (4/5)	100.0 (5/5)	100.0 (5/5)
		2	20.0 (1/5)	100.0 (5/5)	100.0 (5/5)
		3	100.0 (5/5)	100.0 (5/5)	100.0 (5/5)
Bowl 2	y	1	100.0 (5/5)	100.0 (5/5)	100.0 (5/5)
		2	40.0 (2/5)	100.0 (5/5)	100.0 (5/5)
		3	60.0 (3/5)	100.0 (5/5)	100.0 (5/5)
Bowl 1	y	1	100.0 (5/5)	100.0 (5/5)	100.0 (5/5)
		2	100.0 (5/5)	100.0 (5/5)	100.0 (5/5)
		3	100.0 (5/5)	100.0 (5/5)	100.0 (5/5)
Bowl 4	y	1	100.0 (5/5)	100.0 (5/5)	80.0 (4/5)
		2	0.0 (0/5)	0.0 (0/5)	40.0 (2/5)
		3	0.0 (0/5)	60.0 (3/5)	40.0 (2/5)
Bowl 5	y	1	100.0 (5/5)	100.0 (5/5)	100.0 (5/5)
		2	100.0 (5/5)	100.0 (5/5)	80.0 (4/5)
		3	100.0 (5/5)	60.0 (3/5)	100.0 (5/5)
Bowl 6	y	1	100.0 (5/5)	100.0 (5/5)	100.0 (5/5)
		2	100.0 (5/5)	100.0 (5/5)	100.0 (5/5)
		3	100.0 (5/5)	100.0 (5/5)	100.0 (5/5)

で囲われた部分が検出した結果で、その中心の点がニューラルネットワークに入力する座標である。

4.5 実験

データ収集で用いたボウル 3 種類と未学習のボウル 3 種類の計 6 種類のボウルに対して縦横 3×3 の九つの位置でそれぞれ 5 回の自律動作を行い、成功率を検証した。未学習のボウルに対する自律動作では、Bowl4, 5, 6 に対してそれぞれ半径が最も近い Bowl1, 2, 3 のコマンドを入力した。成功判定については、ロボットのハンドがボウルから大きく離れたり、明らかに力が加わっていないような状態にならずにタスクを完了したら成功とした。位置とボウルの種類ごとの成功率を Table 1 に示す。

ボウルがロボットに対して右側や中央の位置に配置されている場合はうまく対応し、常に力を加えながらボウルを拭く動作が確認できた。しかし、ボウルが左側の場合、ロボットのハンドがボウルの内側に移動する際にボウルの縁に引っかかってしまう失敗ケースが多く見られた。これは、今回の拭き動作がボウルの位置にかかわらず右側の壁から拭いていく動作だったため、ボウルが左側に配置されている場合ロボットとの位置関係から動作の精度が必要になってしまったことが原因と考えられる。また、木製のボウルである Bowl1 の実験では、ボウルの縁付近を拭いているところで力を加えすぎてハンドがボウルの外に出てしまう失敗が見られた。これは、Bowl1 が今回使用したボウルの中で最も壁の角度が浅く、教示した拭き動作が横方向に力を加えていたため、力の向きとボウルの面の角度の関係から滑りが発生したと考えられる。これらの失敗に対する改善策としては、ボウルの位置に応じて拭く場所の順番を変えるなど、物体の位置や形状に応じて動作の軌道や力の向きを変えることが挙げられる。

未学習ボウルに対しては、最も小さい Bowl4 では、半径が学習したボウルより小さかったため、ハンドをボウルの内側に移動させるときに縁に当たってボウルの外に出てしまうケースが多く見られた。一方、Bowl5 では、半径がやや小さめのため Bowl4 と同様の縁に当たってしまうケースは見られたものの、学習済みのものと同等程度の成功率を達成できた。また、学習済みボウルより大きい Bowl6 では、すべての試行で成功するこ

とができた。

5. 結 言

本研究では、バイラテラル制御に基づく模倣学習を用いて、大きさや形状の様々なボウルが指定された範囲内で任意の位置に配置された状態での拭き動作を行った。これにより、一つの機械学習モデルで様々な三次元曲面形状の拭き動作が可能であり、面が事前の想定と異なる場合でも対応できることを実証した。本研究の実験は、2022 年 3 月 9 日から 12 日に開催された国際ロボット展で展示を行った。実験では学習範囲の端での検証で失敗が見られたが、学習範囲に余裕を持って含まれる領域では、学習した配置の中間を含めて、4 日間のデモを通して安定した動作を行うことができた。今後の課題としては、今回は入力コマンドを学習に用いた 3 種類のボウルを表す one-hot vector で入力したが、これを半径や曲率のような形状を表す連続値のパラメータに変更し、ニューラルネットワークの内挿性能により、学習した物体の中間の形状へ対応することが考えられる。

参 考 文 献

- [1] B.D. Argall, S. Chernova, M. Veloso and B. Browning: "A survey of robot learning from demonstration," Robotics and autonomous systems, vol.57, no.5, pp.469–483, 2009.
- [2] H. Ravichandar, A. Polydoros, S. Chernova and A. Billard: "Recent advances in robot learning from demonstration," Annual Review of Control, Robotics, and Autonomous Systems, vol.3, no.ARTICLE, pp.297–330, 2020.
- [3] P. Kormushev, S. Calinon and D.G. Caldwell: "Imitation learning of positional and force skills demonstrated via kinesthetic teaching and haptic input," Advanced Robotics, vol.25, no.5, pp.581–603, 2011.
- [4] N. Saito, D. Wang, T. Ogata, H. Mori and S. Sugano: "Wiping 3d-objects using deep learning model based on image/force/joint information," 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pp.10152–10157, 2020.
- [5] Y. Wang, C.C. Beltran-Hernandez, W. Wan and K. Harada: "Hybrid trajectory and force learning of complex assembly tasks: A combined learning framework," IEEE Access, vol.9, pp.60175–60186, 2021.
- [6] T. Adachi, K. Fujimoto, S. Sakaino and T. Tsuji: "Imitation learning for object manipulation based on position/force information using bilateral control," 2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pp.3648–3653, 2018.
- [7] A. Sasagawa, K. Fujimoto, S. Sakaino and T. Tsuji: "Imitation learning based on bilateral control for human–robot cooperation," IEEE Robotics and Automation Letters, vol.5, no.4, pp.6169–6176, 2020.
- [8] T. Murakami, F. Yu and K. Ohnishi: "Torque sensorless control in multidegree-of-freedom manipulator," IEEE Transactions on Industrial Electronics, vol.40, no.2, pp.259–265, 1993.
- [9] K. Ohnishi, M. Shibata and T. Murakami: "Motion control for advanced mechatronics," IEEE/ASME transactions on mechatronics, vol.1, no.1, pp.56–67, 1996.
- [10] K. Hayashi, S. Sakaino and T. Tsuji: "An independently learnable hierarchical model for bilateral control-based imitation learning applications," IEEE Access, vol.10, pp.32766–32781, 2022.
- [11] S. Hochreiter and J. Schmidhuber: "Long short-term memory," Neural computation, vol.9, no.8, pp.1735–1780, 1997.
- [12] R. Rahmatizadeh, P. Abolghasemi, A. Behal and L. Bölöni: "Learning real manipulation tasks from virtual demonstrations using lstm," arXiv preprint arXiv:1603.03833, 2016.