

討論者 中西 弘明 講師

# 特 別 研 究 報 告

## 題 目

触覚とソフトフィンガーを備えた7自由度ロボットアームの模倣学習

指導教員 細田 耕 教授

川節 拓実 講師

京都大学工学部物理工学科  
(機械システム学コース)

氏 名 小森 文雄

提出年月 令和8年2月

## 摘要

近年、複雑なタスクをロボットに実行させる方法として、人間のデモンストレーションから効率的に方策を学習可能な模倣学習が注目されている。特に接触を伴う物体操作タスクにおいては、視覚情報だけでなく、接触時の変形や力を扱うソフトロボット技術との融合が期待されている。本研究では、重力補償制御を実装した7自由度ロボットアームのテレオペレーションシステムを構築し、イオン液体センサを内蔵したソフトフィンガーから得られる触覚データを学習に取り入れることで、接触を伴う繊細なタスクを実行した。提案手法の有効性を検証するため、紙を折るタスクを対象に実機で実験を行い、この模倣学習ロボットシステムの有用性を確認した。

# 目 次

|   |           |
|---|-----------|
| <b>摘要</b>                                   | <b>0</b>  |
| <b>1 緒言</b>                                 | <b>1</b>  |
| <b>2 提案手法</b>                               | <b>2</b>  |
| 2.1 模倣学習のためのロボットシステム . . . . .              | 2         |
| 2.2 操作性に優れたリーダーアーム . . . . .                | 2         |
| 2.3 触覚を統合した模倣学習 . . . . .                   | 6         |
| <b>3 評価実験</b>                               | <b>8</b>  |
| 3.1 触覚情報の有用性の検証 . . . . .                   | 8         |
| 3.2 重力補償がなければできない折り紙タスク . . . . .           | 11        |
| <b>4 議論</b>                                 | <b>13</b> |
| 4.1 7自由度ロボットアームのテレオペレーションシステムについて . . . . . | 13        |
| 4.2 展望 . . . . .                            | 13        |
| <b>5 結言</b>                                 | <b>14</b> |
| <b>謝辞</b>                                   | <b>15</b> |
| <b>参考文献</b>                                 | <b>16</b> |
| <b>付録</b>                                   | <b>17</b> |
| .1 折り紙タスクの実験時のスクリーンショット（時間順） . . . . .      | 17        |

## 1 緒言

近年、ロボットに複雑な作業を習得させる手法として、人間が実演したデータから方策を学習する模倣学習 (imitation learning) が注目されている [1–4]. 従来の数理モデルに基づく制御では記述が困難なタスクであっても、模倣学習を用いることで、多様な環境や対象物に対応可能な柔軟なスキルを獲得できる可能性がある。特に、接触を伴う物体操作タスクにおいては、視覚情報だけでなく、接触時の変形や力を扱うソフトロボット技術との融合が期待されている [5–8]. このように、模倣学習による動作生成能力と、ソフトマテリアルによる環境適応性を統合することは、ロボットが実世界で汎用的なタスクを遂行する上で重要なアプローチとなる。

模倣学習において触覚情報を活用する試みは近年活発化しており、例えば Tactile ALOHA では結束バンドの挿入といった微細な位置合わせ [2] を、Haptic-Informed ACT では壊れやすい物体の把持 [9] を、それぞれ触覚情報を統合することで実現している。ここで、接触を伴う複雑なマニピュレーションの実現には人間の腕のように柔軟な 7 自由度ロボットアーム [10] が有効である。だが、7 自由度ロボットアームは 7 つのモータを使う以上必然的に重量が重くなり、ロボットへの教示データ収集時に操作者に負担を強いる。このような接触を伴う繊細な操作を学習させるためには、質の高い教示データの収集が不可欠であるが、ロボットアームが重さが質の高い接触データの収集を阻害する要因となり得る。

そこで本研究では、模倣学習の教示システムにおいて、教示者の操作するロボットアームに重力補償制御を導入することで、アームの質量を感じさせない直感的な操作感を実現し、微細な力加減や接触状態を含む良質な教示データの効率的な収集を可能にした。また、人間がロボットアームを自分の腕のように直感的に操作しやすくなるグリッパを開発した。

提案手法の有効性を検証するため、紙を折るタスクを対象に実機で実験を行い、この模倣学習システムの有用性を確認した。定量的に重力補償の有無による操作者の負担を比較することはできなかったが、重力補償なしではできないタスクを高い成功率で実行することができ、接触を伴う物体操作タスクにおける本システムの有用性が示された。

本論文の構成は以下の通りである。第 2 章では、模倣学習のためのロボットシステムの概観を示す。第 3 章では、今回開発した操作性に優れたリーダアームについて述べる。第 4 章では、模倣学習手法について説明する。第 5 章では、実機実験の設定と結果を示す。第 6 章では、実験結果に基づく考察を行う。最後に、第 7 章で本研究の結論と今後の展望を述べる。

## 2 提案手法

### 2.1 模倣学習のためのロボットシステム

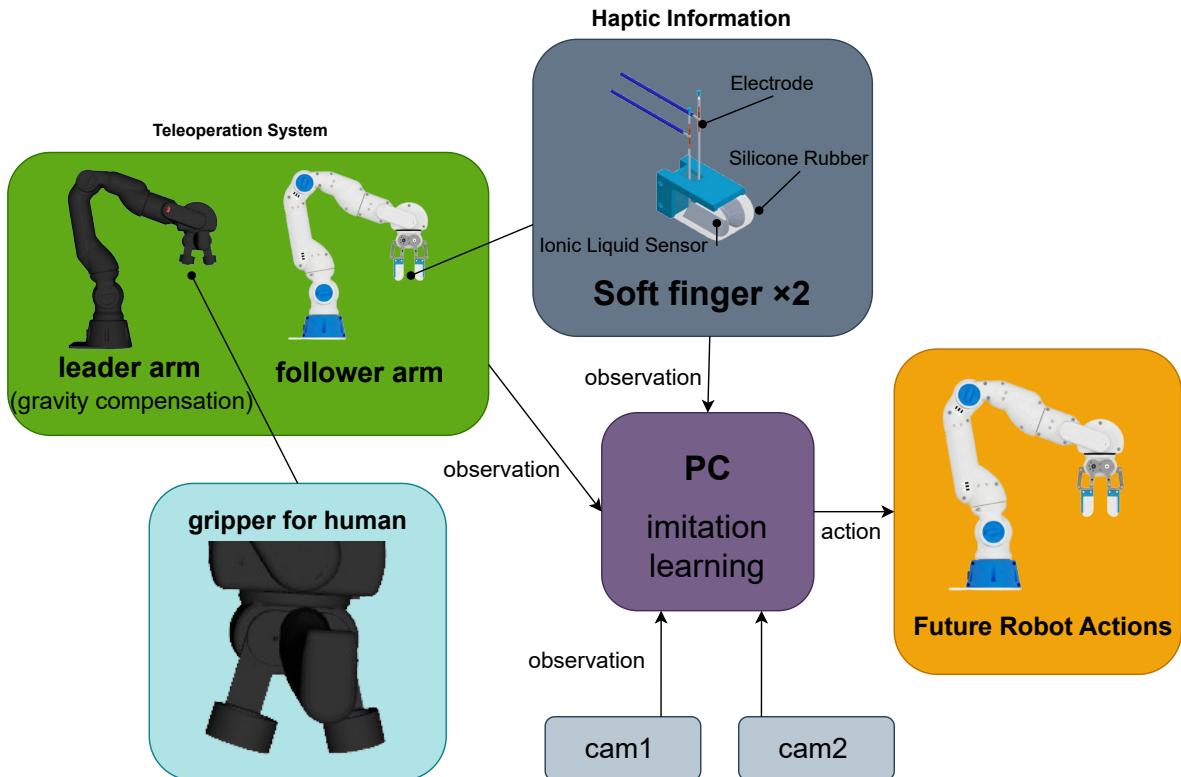


Fig 2.1. Overview of the proposed imitation learning system using a teleoperation setup and haptic information

本章では、提案する重力補償を適用したテレオペレーションシステムと、模倣学習手法について述べる。Fig2.1にシステムの構成図を示す。本システムは、リーダー・フォロワー構成のロボットアーム、フォローアーム先端についている2つのイオン液体センサを内蔵したソフトフィンガー、フォローアームを上からと横から観測するカメラ2台、およびこれらを制御・学習するためのPCから構成される。テレオペレーションによる教示データ収集時には、操作者がリーダーアームを操作し、フォローアームで物体操作を行う。収集した教示データを用いて、模倣学習によりフォローアームの動作モデルを学習する。学習モデルの入力として、カメラ画像、フォローアームの関節角度、およびソフトフィンガーからの触覚情報を用いる。学習後は、フォローアームが自律的に物体操作タスクを実行する。以下に、各構成要素について詳細に述べる。

### 2.2 操作性に優れたリーダーアーム

#### 2.2.1 リーダーアームのグリッパ設計

リーダーアームのグリッパは直感的に操作しやすいように、手のひらで握る用の棒状の把手と、人差し指と親指を差し込むための穴を設けた。これにより、手のひら全体でグリッパを保持しつつ、指先で細かい開閉操作を行うことが可能になる。

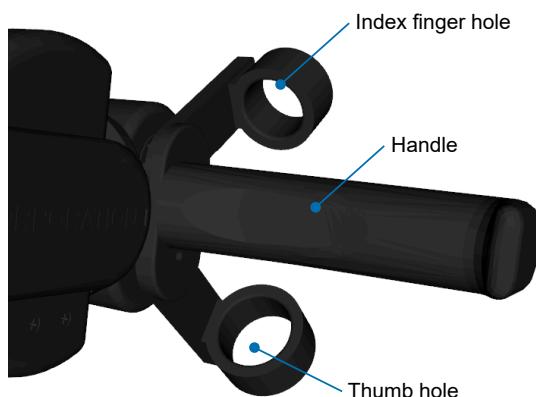


Fig 2.2. Gripper in open state

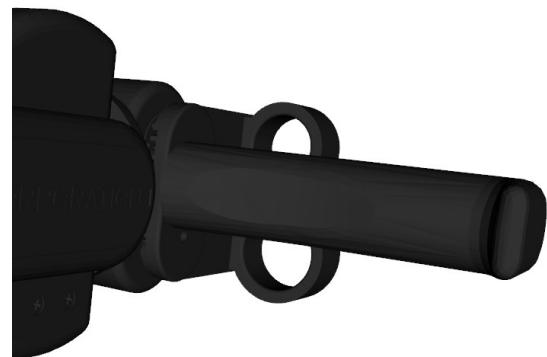


Fig 2.3. Gripper in closed state

また、グリッパを握ると自然とちょうど人間の前腕とリーダーアームの前腕リンクがFig2.4のように対応する。これにより操作者は自分の腕を動かす感覚でリーダーアームを操作できる。

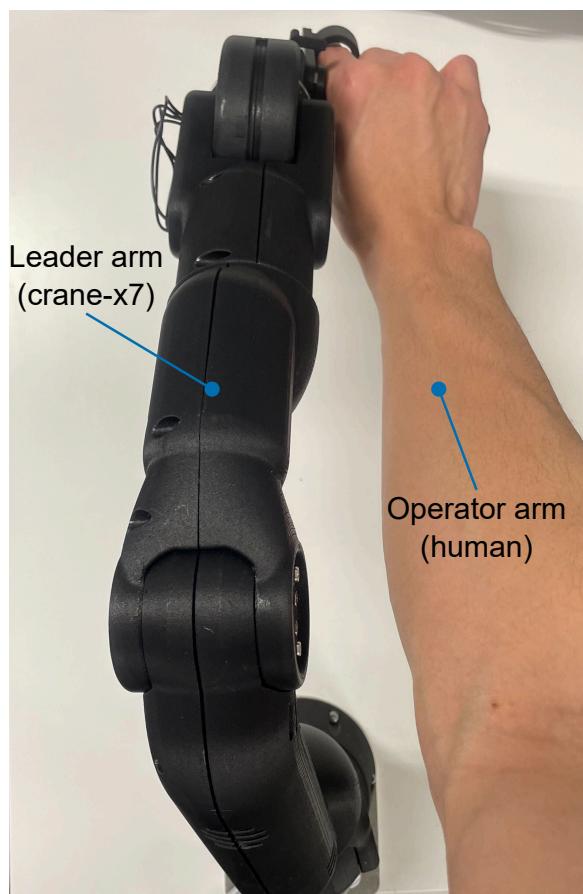


Fig 2.4. Leader arm with operator (overview)



Fig 2.5. Leader gripper held by operator

### 2.2.2 リーダアームに重力補償を適用したテレオペレーションによるデータ収集

本研究では、リーダー・フォロワー方式のテレオペレーションシステムとして、RT社製の7自由度ロボットアームCRANE-X7を2台使用する。マニピュレータの自由度は7自由度、グリッパの自由度は1自由度であり、全体として8自由度のロボットを使用した。1台をリーダアームとして操作者が操作し、もう1台をフォローアームとして物体操作を行う。フォローアームのグリッパにはソフトフィンガーを取り付け、リーダアームの動きに追従し物体操作を実行する。ソフトウェアは、Hugging Faceが提供する模倣学習ライブラリであるlerobotを用いたPython環境をベースとしている。

リーダアームの操作時、CRANE-X7の重量は操作者に負担をかけるため、テレオペレーション時のリーダアームには重力補償制御を適用する。重力補償制御では、ロボットアームの現在関節位置から各関節に作用する重力トルクを計算し、その逆方向のトルクを各関節に加えることで、アームの重量を打ち消す。lerobotはデータ収集から学習、評価までを統一的に扱える優れたフレームワークであるが、重力補償機能はPython実装では制御周期の安定性やリアルタイム性に課題があった。そこで本研究では、RT社の提供するCRANE-X7の重力補償のC++ライブラリをpybibd11を用いてlerobotのPython環境に組み込む実装を行った。これにより、最新の学習フレームワークの恩恵を受けつつ、C++による滑らかで高応答な重力補償制御を両立させている。結果として、操作者はリーダアームの質量を感じることなく、直感的な教示動作を行うことが可能になった。

### 2.2.3 重力補償トルクの算出

本実装では、再帰的ニュートン・オイラー法を用いて、各関節に必要な重力補償トルクを算出した。リンク*i*の質量を*m<sub>i</sub>*、リンク座標系における重心位置ベクトルを*c<sub>i</sub>*、親リンク*i-1*からの回転行列を<sup>*i*</sup>*R<sub>i-1</sub>*とする。

まず、ベースリンク(*i=0*)に対して重力加速度*g*と逆向きの仮想的な加速度 $\ddot{\mathbf{p}}_0 = -\mathbf{g} = [0, 0, 9.8]^T \text{ m/s}^2$ を与える。根本から手先に向かって、各リンクの並進加速度 $\ddot{\mathbf{p}}_i$ および重力による慣性力 $\hat{\mathbf{f}}_i$ を次式で伝播させる。

$$\ddot{\mathbf{p}}_i = {}^i\mathbf{R}_{i-1}\ddot{\mathbf{p}}_{i-1} \quad (2.1)$$

$$\hat{\mathbf{f}}_i = m_i \ddot{\mathbf{p}}_i \quad (2.2)$$

次に、手先から根本に向かって、リンク間に作用する力*f<sub>i</sub>*とモーメント*n<sub>i</sub>*のつり合いを計算する。手先負荷がない場合、末端条件は*f<sub>N+1</sub> = 0, n<sub>N+1</sub> = 0*とする。

$$\mathbf{f}_i = {}^i\mathbf{R}_{i+1}\mathbf{f}_{i+1} + \hat{\mathbf{f}}_i \quad (2.3)$$

$$\mathbf{n}_i = {}^i\mathbf{R}_{i+1}\mathbf{n}_{i+1} + ({}^i\mathbf{p}_{i+1} \times {}^i\mathbf{R}_{i+1}\mathbf{f}_{i+1}) + (\mathbf{c}_i \times \hat{\mathbf{f}}_i) \quad (2.4)$$

ここで、<sup>*i*</sup>*p<sub>i+1</sub>*はリンク*i*原点から子リンク*i+1*原点への位置ベクトルである。

最終的に、関節*i*の駆動軸ベクトル*a<sub>i</sub>*成分を取り出すことで、必要な補償トルク $\tau_i$ が得られる。

$$\tau_i = \mathbf{a}_i^T \mathbf{n}_i \quad (2.5)$$

このトルクを電流値へと変換し各関節のモータに与えることで、重力補償制御を実現している。トルクから電流値への変換係数は、実機に合わせて調整を行った。

### 2.3 触覚を統合した模倣学習

#### 2.3.1 触覚センサを内蔵したソフトロボットフィンガー

フォローアームのハンド部分には、柔軟な把持と接触検知を実現するためにソフトフィンガーを装着する。このフィンガーは柔らかいシリコンゴムの本体と、PLA の爪部分でできており、内部にはイオン液体を封入した流路を持つ触覚センサが埋め込まれている。センサ素子として用いるイオン液体は導電性を有するほか、不揮発性や難燃性、高い熱安定性といった物理的特性を持つ [11]。この液体を柔軟な流路内に封入することで、対象物への接触により流路が変形し、その断面積  $A$  や長さ  $L$  が変化する。この幾何学的な変化は、イオン液体固有の電気抵抗率  $\rho$  を用いて以下の式 (2.6) で表される抵抗値  $R$  の変化として検出される [12]。

$$R = \rho \frac{L}{A} \quad (2.6)$$

なお、本実験ではイオン液体として 1-Butyl-3-methylimidazolium Bis(fluorosulfonyl)imide (関東化学株式会社製) を使用した。ただし、このイオン液体は温度によって抵抗値が多少変化するため、データ収集時と、モデルの評価時に毎回キャリブレーションを行った。

#### 2.3.2 ACT による模倣学習

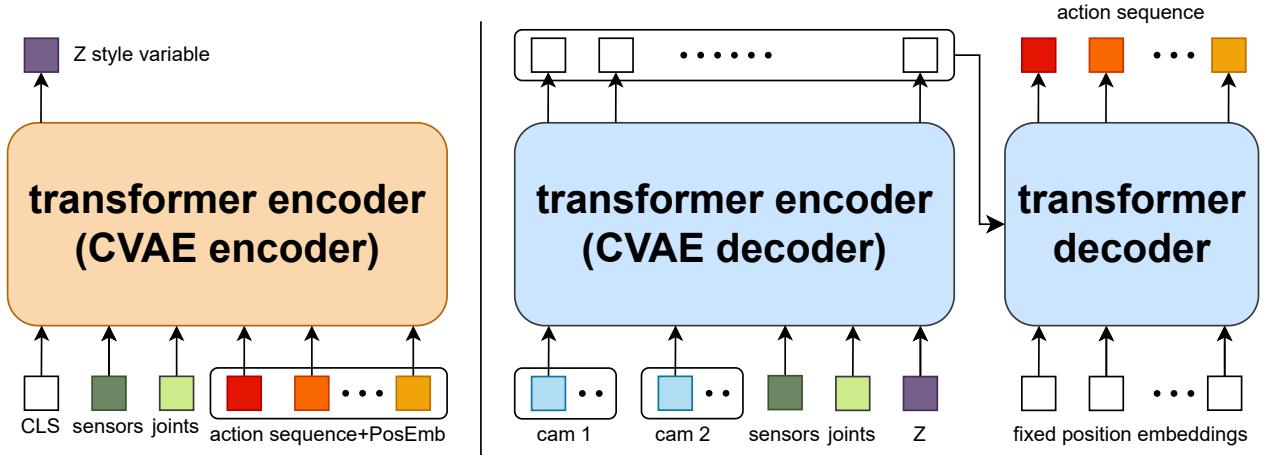


Fig 2.6. Action Chunking with Transformers (ACT) architecture used for imitation learning.

This model extends the conventional ACT framework by introducing distinct sensor embeddings.

本研究では、7自由度ロボットアームで接触を伴う複雑なタスクを学習するために Action Chunking with Transformers (ACT) [2] を基盤としたアーキテクチャを採用する。ACT は Conditional Variational Autoencoder(CVAE) と Transformer を組み合わせたモデルであり、現在の観測から単一の行動ではなく、未来の数ステップ分のアクション系列 (Action Chunk) を一括して予測することで、時系列データの長期的な依存関係を学習することに長けており、滑らかな動作生成が実現できる。

従来の ACT に本アーキテクチャではセンサ値を新たなモダリティとして導入している点が特徴である。具体的には、関節角度と同様にセンサ値をトークン化し、CVAE エンコーダーおよびデコーダーの両方に対して、画像特徴量や関節情報と並列に入力することで、センサ情報を統合した動作生成を可能にしている。

### 3 評価実験

#### 3.1 触覚情報の有用性の検証

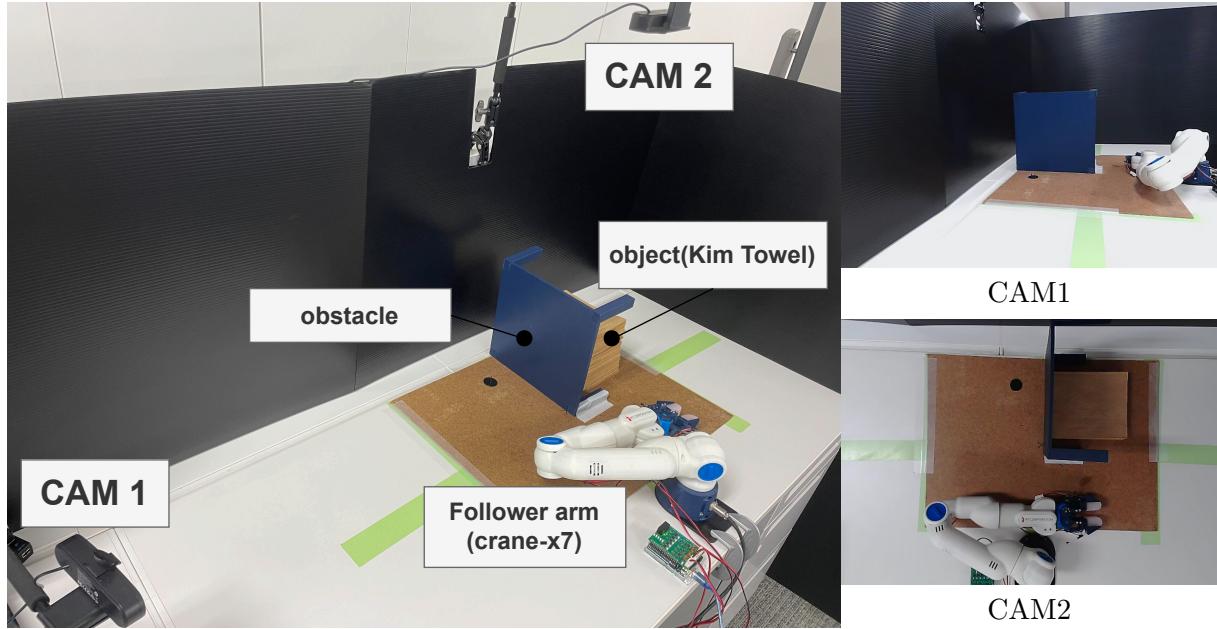


Fig 3.1. Experimental setup for the object-grasping task (left), and example camera views (right): Camera 1 provides a lateral view and Camera 2 provides a top view. An occluding obstacle is placed to simulate bimanual occlusion so that the target object (a Kim towel) is not visible from the lateral viewpoint.

本実験では、触覚情報の有用性を検証するために、触覚センサのデータを含んだ学習と含まない学習の2つの条件で、キムタオルを掴んで別の場所に離すタスクの成功率を比較した。ただし、将来的な双腕でのマニピュレーションを想定し、もう一方のアームによるオクルージョンを疑似的に作り出すため、アームの横からのカメラでキムタオルの高さを見ることができないような障害物を設置した。実験のセットアップを Fig3.1 に示す。

##### 3.1.1 タスクの教示、学習条件

教示データは、キムタオルを Fig3.1 においてある場所にある枚数置いておき、リーダーアームでその上から1枚だけとって紺色の障害物の左側に離す動作をテレオペレーションで行い収集した。この時、双腕を想定した障害物により横からのカメラではキムタオルの高さが見えない。

キムタオルの高さは枚数を 50 枚、40 枚、30 枚、20 枚、10 枚の 5 段階でそれぞれ 2 回の教示データ、合計 10 回の教示データを収集した。教示データ収集時は、センサ値も取得しており、学習時は、その値を無視して学習する `sensor_off` 条件と、センサ値を使用して学習する `sensor_on` 条件の 2 つで学習を行った。

学習の条件は、CPU に AMD Ryzen 9 9950X、GPU に NVIDIA GeForce RTX 5080、メモリ 64GB を搭載した PC を使用した。OS は Ubuntu 24.04.3 LTS (Kernel 6.14) を用いた。学習の batch size は 8、学習ステップ数は 20000 ステップとした。

### 3.1.2 タスクの評価と成功率

タスクの成否は、キムタオルを1枚だけ掴んで、障害物の左側のどこでもいいので移動させることができたら成功とした。ただし、掴み損ねて何度もつかみに行こうとした場合は失敗とした。検証時は教示時のキムタオルの枚数から増やしたものと減らした未知の枚数のものを用意し、全部で60枚、50枚、40枚、30枚、20枚、10枚、1枚の7段階でそれぞれ5回の試行を行い、成功率を算出した。

以下にそれぞれの枚数のキムタオルの様子を示す。

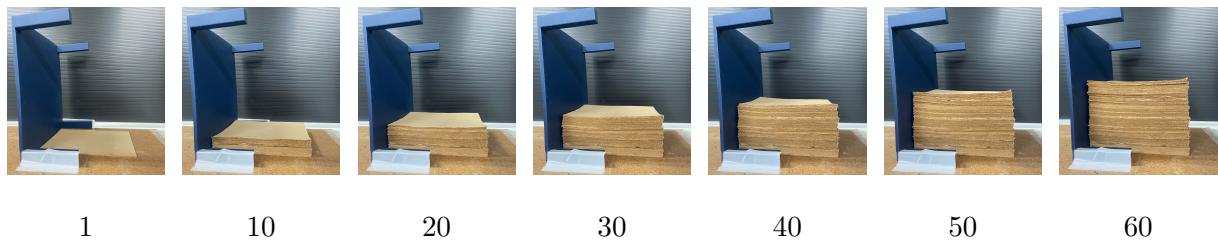


Fig 3.2. Representative images of the Kim towel at each sheet count (1, 10, 20, 30, 40, 50, 60).

さらに、指先のソフトフィンガーの長さを教示時とは短くしたものでも評価を行った。1つ目は教示データと同じ状態、2つ目はそれよりも指の長さが30mm短い状態である。指の長さが長いものにすると、センサ値がない場合に指を強く押し付けすぎて危険なため30mm長いものは使用しなかった。

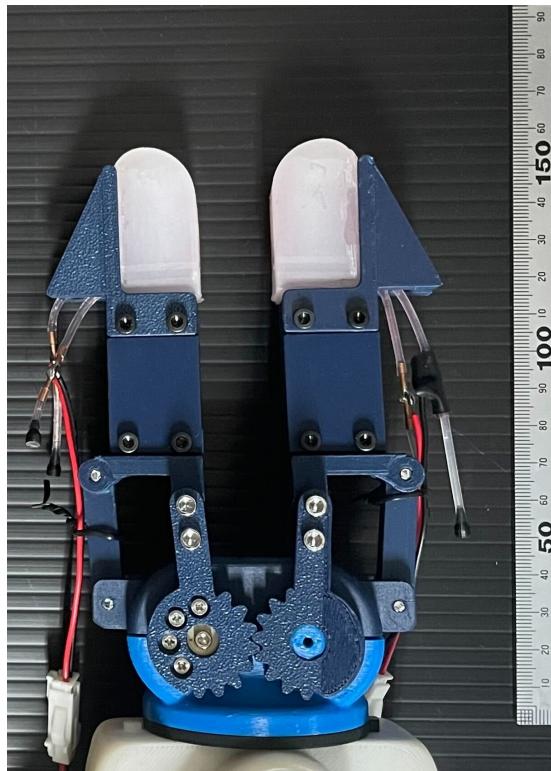


Fig 3.3. Fingers extended by 30mm (same as demonstration)

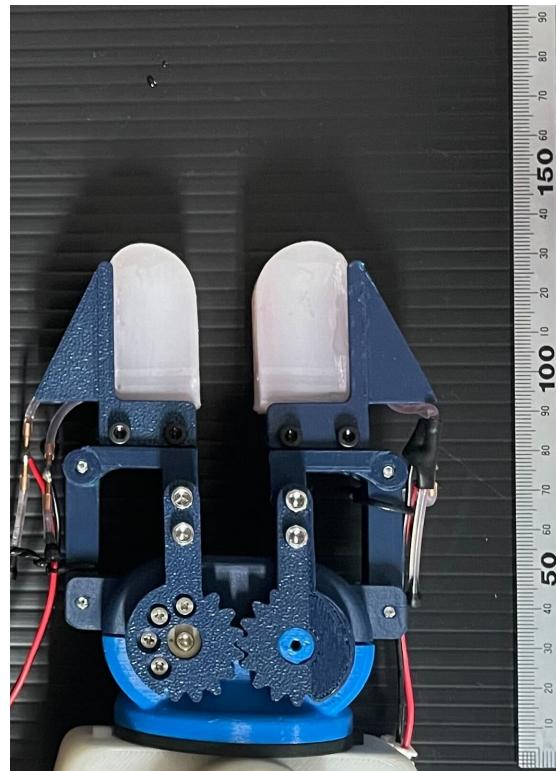


Fig 3.4. Fingers extended by 0mm

以下の表に、各条件での成功率を示す。Table3.1は指先を教示データと同じ長さにした場合、

Table3.2 は指先を 30mm 短くした場合の成功率である。

Table 3.1. Success rate with fingers extended by 30mm (same as demonstration data)

| sheets | sensor_on  | sensor_off |
|--------|------------|------------|
| 60     | 100.0(5/5) | 20.0(1/5)  |
| 50     | 100.0(5/5) | 60.0(3/5)  |
| 40     | 100.0(5/5) | 0.0(0/5)   |
| 30     | 100.0(5/5) | 100.0(5/5) |
| 20     | 100.0(5/5) | 100.0(5/5) |
| 10     | 100.0(5/5) | 100.0(5/5) |
| 1      | 100.0(5/5) | 20.0(1/5)  |

Table 3.2. Success rate with fingers extended by 0mm (different from demonstration data)

| sheets | sensor_on  | sensor_off |
|--------|------------|------------|
| 60     | 100.0(5/5) | 100.0(5/5) |
| 50     | 100.0(5/5) | 80.0(4/5)  |
| 40     | 100.0(5/5) | 100.0(5/5) |
| 30     | 100.0(5/5) | 100.0(5/5) |
| 20     | 80.0(4/5)  | 0.0(0/5)   |
| 10     | 100.0(5/5) | 0.0(0/5)   |
| 1      | 0.0(0/5)   | 0.0(0/5)   |

### 3.2 重力補償がなければできない折り紙タスク

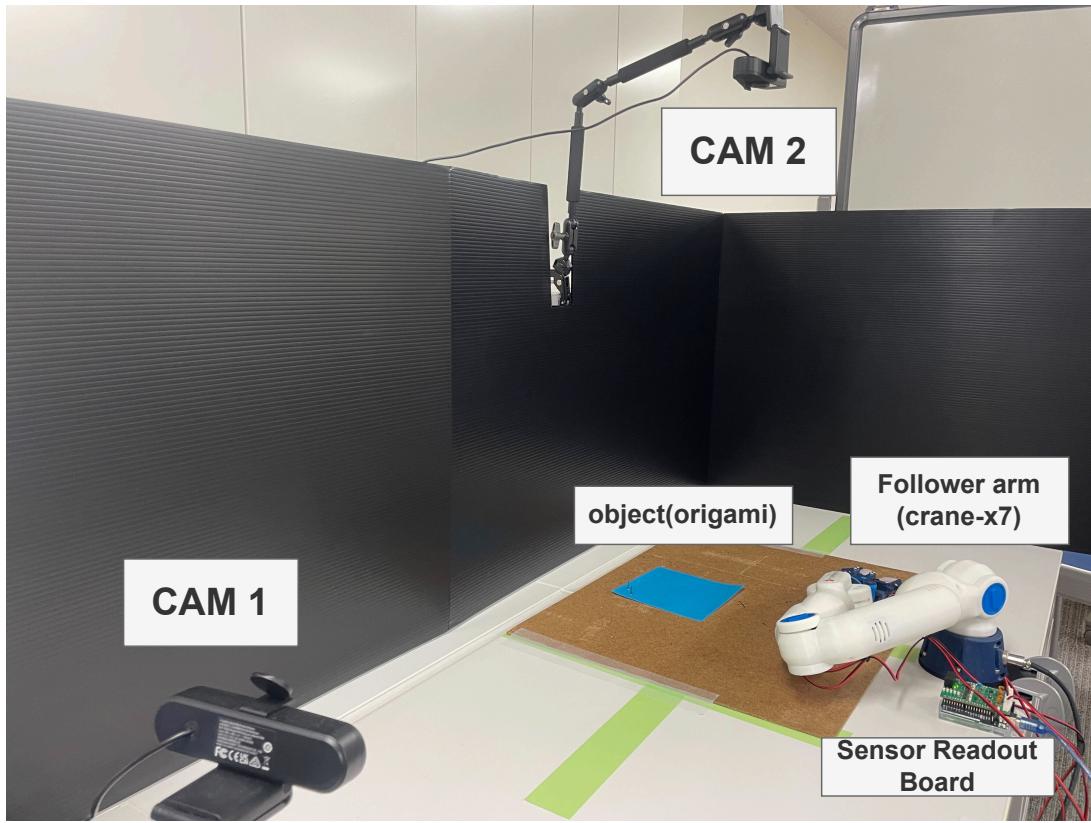


Fig 3.5. Experiment setup (layout, observation cameras, and equipment configuration)

重力補償がなければできないタスクとして、折り紙1枚をソフトフィンガーでつかみ、折り曲げるタスクを行った。ロボットアーム1台で折り紙を折る動作を行うため、折り紙の左端は2点で固定する治具をつけ、折りたたんだ際にも人間がその2点にたたむ紙を刺すという補助を行った。この補助をするためには、操作者が一旦ロボットアームから手を離して折り紙をジグに刺す必要があるため、人間が2人以上いない限りは重力補償制御が不可欠である。

#### 3.2.1 タスクの教示、学習条件

ポリシーは計10回のエピソードを取り、治具の位置は変えずにまず人間がだいたい紙の左上に2点刺すようにセッティングした。そのため、紙の位置は毎回微妙にずれている。各エピソードで、操作者はリーダーアームを操作して折り紙を折り、一旦折ったらその状態でアームを重力補償下で固定し、紙を治具の2点に刺すという補助を行い、折り目をつける段階へと移行した。

学習の条件は、CPUにAMD Ryzen 9 9950X、GPUにNVIDIA GeForce RTX 5080、メモリ64GBを搭載したPCを使用した。OSはUbuntu 24.04.3 LTS (Kernel 6.14) を用いた。学習のbatch sizeは8、学習ステップ数は20000ステップとした。

また、センサ値は生データをそのまま使用すると、温度変化によって異なる値を示すため、キャリブレーションを行った。具体的には、各試行の開始時に5秒間静止した状態でセンサ値を取得し、その平均値を基準として各時刻のセンサ値から引き算することで、実験を行う日程や時間帯の変化による温度変化の影響を抑制した。

### 3.2.2 タスクの評価と成功率

折り紙を他に折り目をつけずに教示時と同じ向きに折りたたむことができ、折り紙を自然にしたときに折り目が開かなければ成功とした。10回の試行を行い、9回成功し、成功率は90%であった。

ここで、重力補償がなければそもそも教示ができないため、成功率は0%であるといえる。

## 4 議論

### 4.1 7自由度ロボットアームのテレオペレーションシステムについて

本研究では、触覚とソフトフィンガーを備えた7自由度ロボットアームの模倣学習により、折り紙を折るという複雑なタスクを実現した。重力補償がない状態での教示データ収集においては、常に両手でロボットアームを支えている必要があり、片手での操作はほぼ不可能であった。一方、重力補償制御を導入することで、ロボットアームの重量を感じさせない直感的な操作感が得られ、ある程度までなら片手での操作が可能となった。そのうえ、ロボットアームのある位置に固定することが容易になり、固定した状態で人間がロボットアームから手を離してロボットと協働してタスクを補助することができるようになった。定量的に重力補償の有無による操作者の負担を比較することはできなかったが、実機を通して重力補償の有無を経験することで、教示データ収集時の操作者の主観的な負担が軽減されたことは明らかであった上、操作の幅が広がるということが分かった。

### 4.2 展望

今後、この知見を活かして、双腕でのマニピュレーションタスクや、より複雑なタスクへの応用を検討する。特に、双腕ロボットシステムにおいては、片方のアームで物体を保持しながらもう片方のアームで操作を行う場面が多く、重力補償制御が操作者の負担軽減に大きく寄与することが予想される。また、触覚情報を活用することで、腕が2本になることにより必然的に増えるセルフオクルージョンの問題を緩和し、より精密な操作が可能になると考えられる。

## 5 結言

## 謝　　辞

本研究の実施や論文の執筆にあたり、多くの方々にご指導とご協力をいただきましたことに、心より感謝申し上げます。京都大学大学院工学研究科機械理工学専攻の細田耕教授、川節拓実講師には、熱心にご指導いただきました。研究室秘書の堀祐子さんには、研究に関わることだけでなく、研究室での生活や様々な場面でお世話になりました。また、研究室の先輩方には様々な助言や激励の言葉をいただき、特に辻大樹さんには、研究に関することについて何度も相談に乗ってくださいました。慣れない環境で初めて研究に取り掛かり、不安なこともたくさんありましたが、研究室同期で話す時間が何より励みになりました。

本研究は以上の方々のサポートがなければ終えることは出来ませんでした。この場を借りて深く感謝申し上げます。

令和8年2月 小森 文雄

## 参考文献

- [1] Stefan Schaal. Learning from Demonstration. In *Advances in Neural Information Processing Systems*, Vol. 9. MIT Press, 1996.
- [2] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware, April 2023.
- [3] 広暉山根, 勇樹七種, 翔境野, 俊明辻. バイラテラル制御に基づく模倣学習による三次元曲面拭き動作の学習. 日本ロボット学会誌, Vol. 41, No. 4, pp. 395–398, 2023.
- [4] Koki Yamane, Yuki Saigusa, Sho Sakaino, and Toshiaki Tsuji. Soft and Rigid Object Grasping With Cross-Structure Hand Using Bilateral Control-Based Imitation Learning. *IEEE Robotics and Automation Letters*, Vol. 9, No. 2, pp. 1198–1205, February 2024.
- [5] Cheng Chi, Xuguang Sun, Ning Xue, Tong Li, and Chang Liu. Recent Progress in Technologies for Tactile Sensors. *Sensors*, Vol. 18, No. 4, p. 948, April 2018.
- [6] Ravinder S. Dahiya, Giorgio Metta, Maurizio Valle, and Giulio Sandini. Tactile Sensing—From Humans to Humanoids. *IEEE Transactions on Robotics*, Vol. 26, No. 1, pp. 1–20, February 2010.
- [7] Su-Ting Han, Haiyan Peng, Qijun Sun, Shishir Venkatesh, Kam-Sing Chung, Siu Chuen Lau, Ye Zhou, and V. a. L. Roy. An Overview of the Development of Flexible Sensors. *Advanced Materials*, Vol. 29, No. 33, p. 1700375, 2017.
- [8] Jun Shintake, Vito Cacucciolo, Dario Floreano, and Herbert Shea. Soft Robotic Grippers. *Advanced Materials*, Vol. 30, No. 29, p. 1707035, 2018.
- [9] Pedro Miguel Uriguén Eljuri, Hironobu Shibata, Maeyama Katsuyoshi, Yuanyuan Jia, and Tadahiro Taniguchi. Haptic-Informed ACT with a Soft Gripper and Recovery-Informed Training for Pseudo Oocyte Manipulation, July 2025.
- [10] J. Rosen, J.C. Perry, N. Manning, S. Burns, and B. Hannaford. The human arm kinematics and dynamics during daily activities - toward a 7 DOF upper limb powered exoskeleton. In *ICAR '05. Proceedings., 12th International Conference on Advanced Robotics, 2005.*, pp. 532–539, July 2005.
- [11] Michel Armand, Frank Endres, Douglas R. MacFarlane, Hiroyuki Ohno, and Bruno Scrosati. Ionic-liquid materials for the electrochemical challenges of the future. *Nature Materials*, Vol. 8, No. 8, pp. 621–629, August 2009.
- [12] Jean-Baptiste Chossat, Yong-Lae Park, Robert J. Wood, and Vincent Duchaine. A Soft Strain Sensor Based on Ionic and Metal Liquids. *IEEE Sensors Journal*, Vol. 13, No. 9, pp. 3405–3414, September 2013.

## 付 錄

### 7 自由度ロボットの仕様

型番: RT-CRANE-X7

作業有効範囲: 500mm

可搬重量: 約 0.5kg

自由度: 7

エンドエフェクタ: 両開きハンド 1

サイズ: 130 × 100 × 708(mm) (設置用固定金属 5mm 含む)

重量: 約 1.5kg

通信: 内部は RS485 通信

内蔵モータ: ROBOTIS 製 XM540-W270-R,XM430-W350-R 搭載

電源: 12V10A 120W 純電

筐体ボディ: 3D プリンタ仕上げ

使用した RGB カメラ

EMEET SmartCam C960 2 台

今回の cranex7 の leaderarm の重力補償のモータごとのトルク電流比のキャリブレーション値を以下に示す。ただし、ベース部分の関節である ID2, グリッパ部分の ID8, ID9 については重力補償制御を適用していないため省略する。

ID3: torque\_to\_current = 0.2267

ID4: torque\_to\_current = 0.3245

ID5: torque\_to\_current = 0.3035

ID6: torque\_to\_current = 0.2545

ID7: torque\_to\_current = 0.1515

Compensation gain: 0.4

Current limit: 350.0mA

### .1 折り紙タスクの実験時のスクリーンショット（時間順）

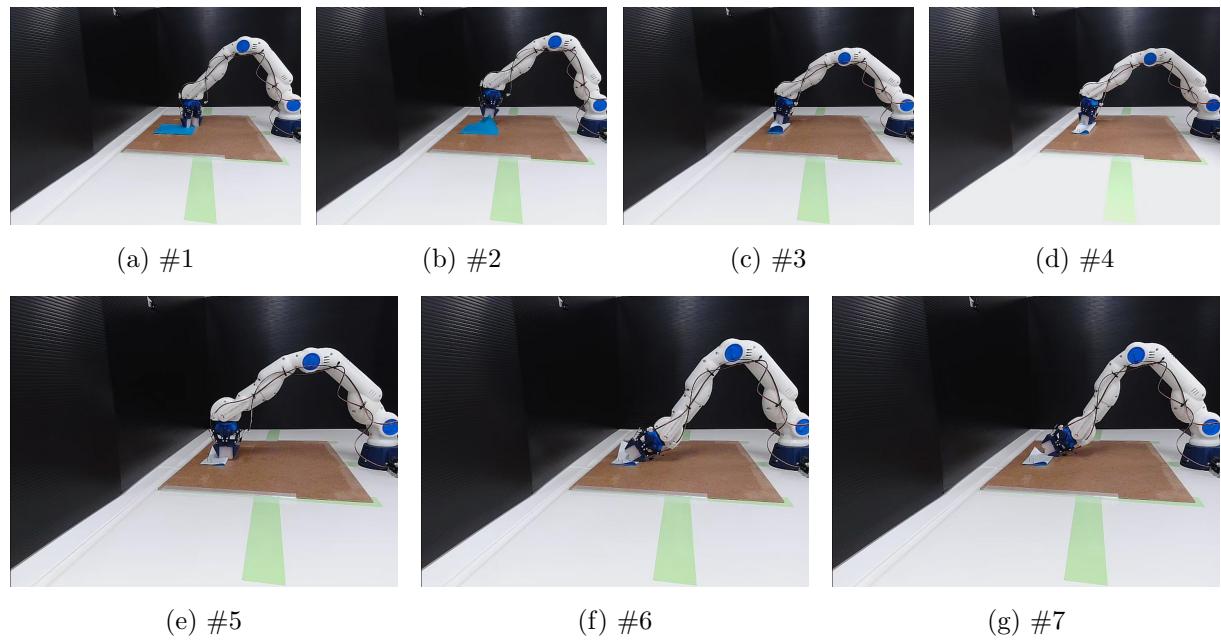


Fig A.1. Sequence of screenshots captured during the experiment (time order).