

討論者 中西 弘明 講師

特 別 研 究 報 告

題 目

触覚とソフトフィンガーを備えた7自由度ロボットアームの模倣学習

指導教員 細田 耕 教授

川節 拓実 講師

京都大学工学部物理工学科
(機械システム学コース)

氏 名 小森 文雄

提出年月 令和8年2月

摘要

近年、複雑なタスクをロボットに実行させる方法として、人間のデモンストレーションから効率的に方策を学習可能な模倣学習が注目されている。特に接触を伴う物体操作タスクにおいては、視覚情報だけでなく、接触時の変形や力を扱うソフトロボット技術との融合が期待されている。

本研究では、重力補償制御を実装した7自由度ロボットアームのテレオペレーションシステムを教示の基盤として構築し、イオン液体センサを内蔵したソフトフィンガーの触覚データを取り入れた模倣学習手法を提案する。提案手法の評価として、キムタオルの把持タスクと紙を折るタスクを対象に実機実験を行った。キムタオルの把持タスクの結果から触覚情報の統合により、環境変動に対してロバストな柔軟物体把持を高い成功率で学習可能であることが示された。また、紙を折るタスクによって重力補償を取り入れた本システムが、操作の中斷を伴う複雑な教示工程において重要であることが確認された。

目 次

摘要	0
1 緒言	1
2 提案手法	2
2.1 模倣学習のためのロボットシステム概要	2
2.2 触覚を統合した模倣学習	3
2.3 操作性に優れたリーダーアーム	5
3 評価実験	8
3.1 触覚情報の有用性を示すキムタオル把持タスク	8
3.2 重力補償を導入した操作しやすいリーダーアームによって容易になる折り紙タスク	12
4 議論	17
4.1 触覚情報の活用による把持成功率の向上	17
4.2 重力補償制御によるタスクの幅の拡大	18
5 結言	19
謝辞	20
付録	21

1 緒言

近年、ロボットに複雑な作業を習得させる手法として、人間が実演したデータから方策を学習する模倣学習 (imitation learning) が注目されている [?, ?, ?]. 従来の数理モデルに基づく制御では記述が困難なタスクであっても、模倣学習を用いることで、多様な環境や対象物に対応可能な柔軟なスキルを獲得できる可能性がある [?, ?]. 特に、接触を伴う物体操作タスクにおいては、視覚情報だけでなく、接触時の変形や力を扱うソフトロボット技術との融合が期待されている [?, ?, ?, ?, ?]. このように、模倣学習による動作生成能力と、ソフトマテリアルによる環境適応性を統合することは、ロボットが実世界で汎用的なタスクを遂行する上で重要なアプローチとなる。

模倣学習において触覚情報を活用する試みは近年活発化しており、例えば Tactile ALOHA では結束バンドの挿入といった微細な位置合わせ [?] を、Haptic-Informed ACT では壊れやすい物体の把持 [?] を、それぞれ触覚情報を統合することで実現している。しかし、従来の硬い触覚センサやグリッパでは、対象物の形状にじむことが難しく、不定形物や壊れやすい物体に対しては局所的な応力集中により損傷を与えるリスクがあった [?]. そこで本研究では、柔軟なシリコンゴム内部にイオン液体流路を埋め込んだソフトフィンガー [?] を採用する。このフィンガーは、対象物に接触した際に自身の形状を柔軟に変形させることで、対象物を傷つけることなく優しく把持できる。この形状適合性と、内部の流路変形に基づく触覚センシングを組み合わせることで、視覚だけでは捉えきれない接触状態をタスク遂行に活用することを目的とする。

また、このような柔軟な指による繊細なマニピュレーションを学習させるためには、教示データ自体が高品質であることが求められる。人間の腕のように柔軟な動作が可能な 7 自由度ロボットアーム [?] は複雑なタスクに適している一方で、自由度が多い分自重が重く、ソフトフィンガーの特性を活かした繊細な接触動作を教示する上で、操作の直感性を損なう要因となり得る。そこで本研究では、主要な提案であるソフトフィンガーを用いた模倣学習を支える基盤として、リーダーアームに重力補償制御を導入したテレオペレーションシステムを構築した。これにより、教示者がアームの重量を感じることなく、自身の腕の延長のように直感的に操作することが可能となり、質の高い教示データの収集を実現している。

提案手法の有効性を検証するため、キムタオルの把持タスクと紙を折るタスクを対象に実機で実験を行った。キムタオルの把持タスクでは、ソフトフィンガーの柔軟性と触覚情報の統合により、視覚情報だけでは困難な状況下でも、環境変動に対してロバストな物体把持が高い成功率で学習可能であることを示した。また、紙を折るタスクを通じ、重力補償を取り入れた教示システムが、複雑な工程を含むタスクにおいて操作者の負担を軽減し、円滑なデータ収集に寄与することを確認した。

本論文の構成は以下の通りである。第 2 章では、ソフトフィンガーからの触覚を統合した模倣学習の枠組みと、それを支える重力補償付きテレオペレーションシステムについて述べる。第 3 章では、模倣学習の実験の内容と結果を示す。第 4 章では結果を基に考察する。最後に、第 5 章で本研究の結論と今後の展望を述べる。

2 提案手法

2.1 模倣学習のためのロボットシステム概要

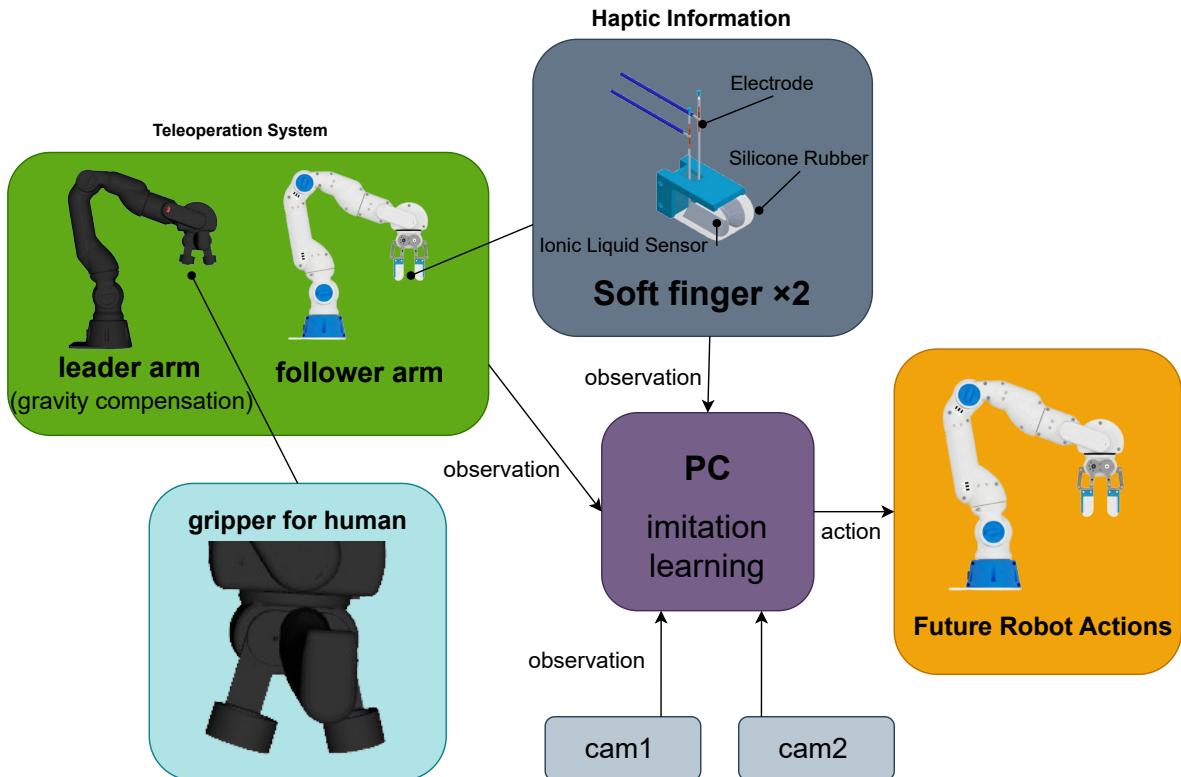


Fig 2.1. Overview of the proposed imitation learning system using a teleoperation setup and haptic information

本章では、提案する重力補償を適用したテレオペレーションシステムと、模倣学習手法について述べる。Fig2.1にシステムの構成図を示す。本システムは、リーダー・フォロワー構成のロボットアーム、フォローアーム先端についている2つのイオン液体センサを内蔵したソフトフィンガー、フォローアームを側面と上面から観測するカメラ2台、およびこれらを制御・学習するためのPCから構成される。テレオペレーションによる教示データ収集時には、操作者がリーダーアームを操作し、フォローアームで物体操作を行う。収集した教示データを用いて、模倣学習によりフォローアームの動作モデルを学習する。学習モデルの入力として、カメラ画像、フォローアームの関節角度、およびソフトフィンガーからの触覚情報を用いる。学習後は、フォローアームが自律的に物体操作タスクを実行する。以下に、各構成要素について詳細に述べる。

2.2 触覚を統合した模倣学習

2.2.1 触覚センサを内蔵したソフトロボットフィンガー

フォローアームのハンド部分には、柔軟な把持と接触検知を実現するためにソフトフィンガーを装着する。このフィンガーは柔らかいシリコンゴムの本体と、PLA の爪部分でできており、内部にはイオン液体を封入した流路を持つ触覚センサが埋め込まれている。センサ素子として用いるイオン液体は導電性を有するほか、不揮発性や難燃性、高い熱安定性といった物理的特性を持つ^[?]。この液体を柔軟な流路内に封入することで、対象物への接触により流路が変形し、その断面積 A や長さ L が変化する。この幾何学的な変化は、イオン液体固有の電気抵抗率 ρ を用いて式 $R = \rho \frac{L}{A}$ で表される抵抗値 R の変化として検出される^[?]。

なお、本実験ではイオン液体として 1-Butyl-3-methylimidazolium Bis(fluorosulfonyl)imide（関東化学株式会社製）を使用した。なお、このイオン液体の電気抵抗値は温度依存性を持つため^[?]、抵抗値は環境温度によって変動する。そこで本システムでは、データ収集および評価実験の各試行開始時にキャリブレーション（ゼロ点補正）を行うことで、温度変化によるドリフトの影響を抑制している。

2.2.2 ACT による模倣学習

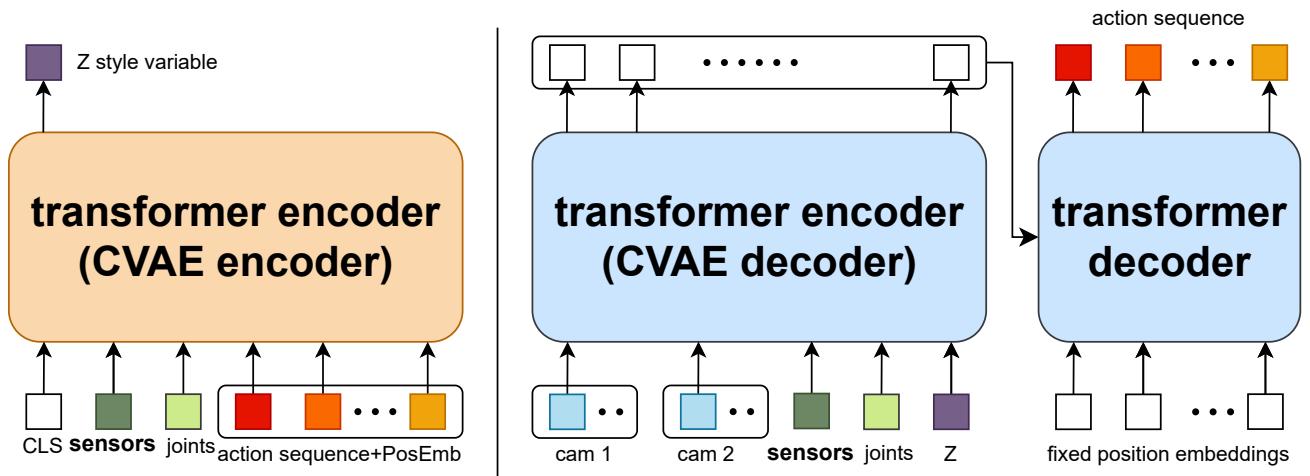


Fig 2.2. Action Chunking with Transformers (ACT) architecture used for imitation learning.

This model extends the conventional ACT framework by introducing distinct sensor embeddings.

本研究では、7自由度ロボットアームで接触を伴う複雑なタスクを学習するために Action Chunking with Transformers (ACT)^[?]を基盤としたアーキテクチャを採用する。ACT は Conditional Variational Autoencoder(CVAE) と Transformer を組み合わせたモデルであり、現在の観測から单一の行動ではなく、未来の数ステップ分のアクション系列 (Action Chunk) を一括して予測することで、時系列データの長期的な依存関係を学習することに長けており、滑らかな動作生成が実現できる。

従来の ACT に本アーキテクチャではセンサ値を新たなモダリティとして導入している点が特徴

である。具体的には、関節角度と同様にセンサ値をトークン化し、CVAE エンコーダーおよびデコーダーの両方に対して、画像特徴量や関節情報と並列に入力することで、センサ情報を統合した動作生成を可能にしている。

2.3 操作性に優れたリーダーアーム

2.3.1 リーダーアームのグリッパ設計

リーダーアームの操作性を向上させるため、人間の手による把持に適した形状のグリッパを設計した (Fig. 2.3, Fig. 2.4)。本グリッパは、手掌部で安定して保持可能な円筒形状のグリップと、人差し指・親指を挿入するための操作用リングを備えている。これにより、操作者は手のひら全体でグリッパを支えつつ、指先を用いて繊細な開閉操作を行うことが可能となる。

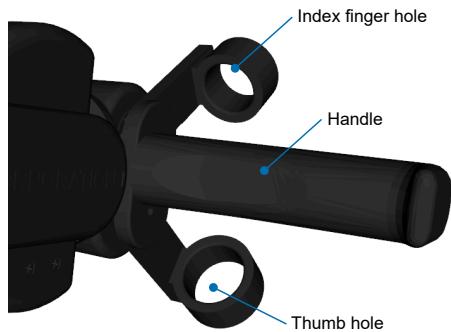


Fig 2.3. Gripper in open state

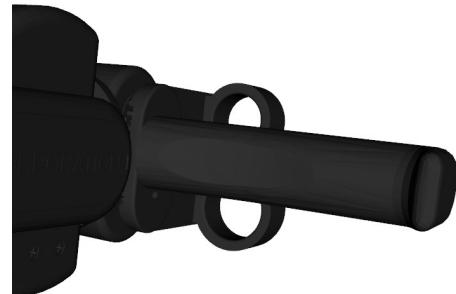


Fig 2.4. Gripper in closed state

また、操作者がグリッパを持った際、人間の前腕とリーダーアームの前腕リンクが幾何学的に対応するよう設計されている (Fig. 2.5, Fig. 2.6)。これにより、操作者は自身の腕の延長としてリーダーアームを直感的に操作することが可能となり、学習に適した自然な教示データの収集が容易となる。



Fig 2.5. Leader arm with operator (overview)



Fig 2.6. Leader gripper held by operator

2.3.2 リーダアームに重力補償を適用したテレオペレーションによるデータ収集

本研究では、リーダー・フォロワー方式のテレオペレーションシステムとして、RT社製の7自由度ロボットアームCRANE-X7を2台使用する。マニピュレータの自由度は7自由度、グリッパの自由度は1自由度であり、全体として8自由度のロボットを使用した。1台をリーダアームとして操作者が操作し、もう1台をフォローアームとして物体操作を行う。フォローアームのグリッパにはソフトフィンガーを取り付け、リーダアームの動きに追従し物体操作を実行する。ソフトウェアは、Hugging Faceが提供する模倣学習ライブラリであるlerobot[?]を用いたPython環境をベースとしている。

リーダアームの操作時、CRANE-X7の重量は操作者に負担をかけるため、テレオペレーション時のリーダアームには重力補償制御を適用する。重力補償制御では、ロボットアームの現在関節位置から各関節に作用する重力トルクを計算し、その逆方向のトルクを各関節に加えることで、アームの重量を打ち消す。lerobotはデータ収集から学習、評価までを統一的に扱える優れたフレームワークであるが、重力補償機能はPython実装では制御周期の安定性やリアルタイム性に課題があった。そこで本研究では、RT社の提供するCRANE-X7の重力補償のC++ライブラリをpybibd11を用いてlerobotのPython環境に組み込む実装を行った。これにより、最新の学習フレームワークの恩恵を受けつつ、C++による滑らかで高応答な重力補償制御を両立させている。結果として、操作者はリーダアームの質量を感じることなく、直感的な教示動作を行うことが可能になった。

2.3.3 重力補償トルクの算出

本実装では、再帰的ニュートン・オイラー法を用いて、各関節に必要な重力補償トルクを算出した。リンク*i*の質量を*m_i*、リンク座標系における重心位置ベクトルを*c_i*、親リンク*i-1*からの回転行列を^{*i*}*R_{i-1}*とする。

まず、ベースリンク(*i=0*)に対して重力加速度*g*と逆向きの仮想的な加速度 $\ddot{\mathbf{p}}_0 = -\mathbf{g} = [0, 0, 9.8]^T \text{ m/s}^2$ を与える。根本から手先に向かって、各リンクの並進加速度 $\ddot{\mathbf{p}}_i$ および重力による慣性力 $\hat{\mathbf{f}}_i$ を次式で伝播させる。

$$\ddot{\mathbf{p}}_i = {}^i\mathbf{R}_{i-1}\ddot{\mathbf{p}}_{i-1} \quad (2.1)$$

$$\hat{\mathbf{f}}_i = m_i \ddot{\mathbf{p}}_i \quad (2.2)$$

次に、手先から根本に向かって、リンク間に作用する力*f_i*とモーメント*n_i*のつり合いを計算する。手先負荷がない場合、末端条件は*f_{N+1}=0, n_{N+1}=0*とする。

$$\mathbf{f}_i = {}^i\mathbf{R}_{i+1}\mathbf{f}_{i+1} + \hat{\mathbf{f}}_i \quad (2.3)$$

$$\mathbf{n}_i = {}^i\mathbf{R}_{i+1}\mathbf{n}_{i+1} + ({}^i\mathbf{p}_{i+1} \times {}^i\mathbf{R}_{i+1}\mathbf{f}_{i+1}) + (\mathbf{c}_i \times \hat{\mathbf{f}}_i) \quad (2.4)$$

ここで、^{*i*}*p_{i+1}*はリンク*i*原点から子リンク*i+1*原点への位置ベクトルである。

最終的に、関節*i*の駆動軸ベクトル*a_i*成分を取り出すことで、必要な補償トルク τ_i が得られる。

$$\tau_i = \mathbf{a}_i^T \mathbf{n}_i \quad (2.5)$$

このトルクを電流値へと変換し各関節のモータに与えることで、重力補償制御を実現している。トルクから電流値への変換係数は、実機に合わせて調整を行った。

3 評価実験

3.1 触覚情報の有用性を示すキムタオル把持タスク

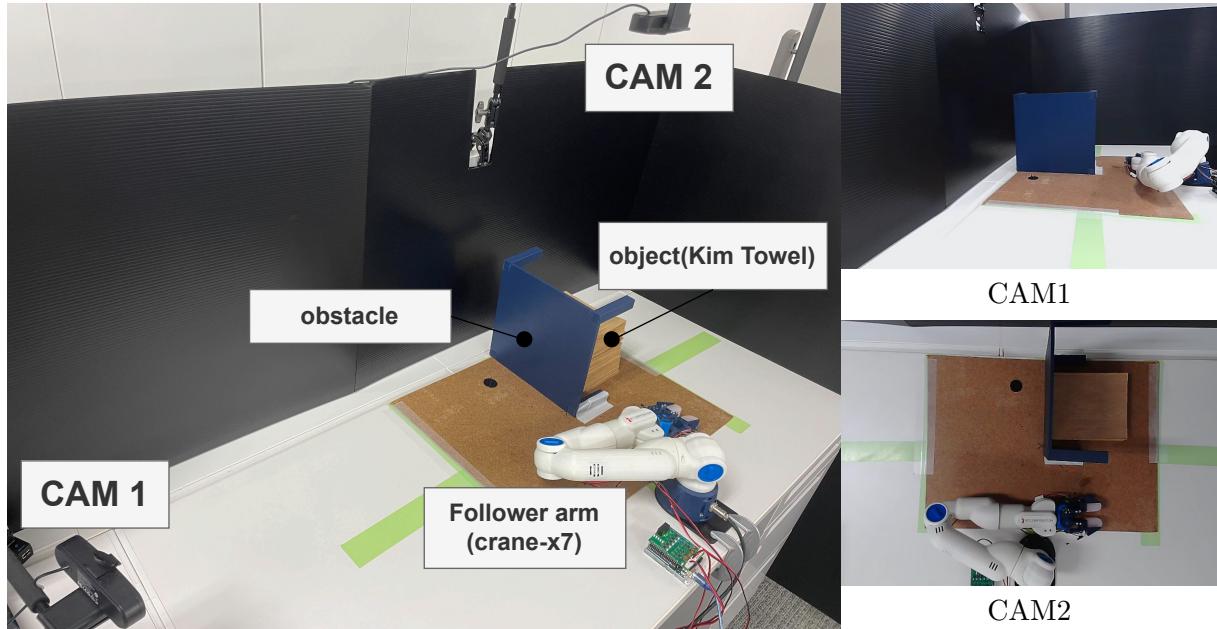


Fig 3.1. Experimental setup for the object-grasping task (left), and example camera views (right): Camera 1 provides a lateral view and Camera 2 provides a top view. An occluding obstacle is placed to simulate bimanual occlusion so that the target object (a Kim towel) is not visible from the lateral viewpoint.

本実験では、提案手法における触覚情報の有用性を検証するため、触覚センサ情報の有無 (sensor_on / sensor_off) がタスク成功率に与える影響を比較した。タスクは、積層されたキムタオルを持ちし、所定の場所へ搬送する動作とした。なお、実験環境の構築にあたっては、双腕ロボットによる協調作業や深箱内の物体操作において発生しうる、視覚的な閉塞（オクルージョン）状況を再現した。具体的には、Fig. 3.1 に示すように紺色の障害物を設置し、側面カメラ（Camera 1）からは対象物（キムタオル）の高さ情報が得られない環境を構築した。

3.1.1 タスクの教示、学習条件

教示データ収集では、Fig. 3.1 に示すセットアップにおいて、リーダーアームを用いたテレオペレーションにより、積層されたキムタオルの最上位 1 枚のみを持ちし、障害物の左側へ搬送する動作を行った。この際、正面の障害物を回避しながらアプローチする必要があるため、7 自由度アームの冗長性を活かした操作が要求される。

対象物であるキムタオルの積層枚数は、50 枚、40 枚、30 枚、20 枚、10 枚の 5 段階とし、各条件につき 2 回、計 10 回分の教示データを収集した。データ収集時には触覚センサの生データ値も記録し、学習時にはこのセンサ値を使用しない条件 (sensor_off) と、使用する条件 (sensor_on) の 2 条件でモデルを生成した。

学習モデルのトレーニングは、AMD Ryzen 9 9950X CPU, NVIDIA GeForce RTX 5080 GPU (16GB), および 64GB のメモリを搭載した PC (OS: Ubuntu 24.04.3 LTS) を用いて実施した。ハイパーパラメータに関しては、バッチサイズを 8, 学習ステップ数を 20,000 ステップに設定した。

また、本研究で使用するイオン液体センサは、周囲温度の変化に伴いベースラインとなる抵抗値が変動する特性を持つ。この環境変動（温度ドリフト）の影響を排除するため、各データ収集セットの開始時にキャリブレーション処理を導入した。具体的には、動作開始前の 5 秒間におけるセンサ値を静止状態で取得し、その平均値を初期オフセット値として算出する。タスク実行中は、取得された生データからこのオフセット値を減算した値を学習および推論への入力とすることで、実験ごとの温度条件の差異を正規化した。

3.1.2 タスクの評価と成功率

タスクの成功条件は、「積層されたキムタオルから 1 枚のみを把持し、障害物左側の目標領域へ搬送すること」と定義した。目標領域は障害物の左側全域である。最初の把持動作でキムタオルを掴み損ねてロボットが自律的に再把持（リトライ）動作を行った場合は、それ以降の動作にかかわらず失敗と判定した。

評価実験では、教示データに含まれない未知の環境に対する汎化性能を検証するため、教示時の枚数条件 (10, 20, 30, 40, 50 枚) に加え、教示範囲外となる 60 枚および 1 枚の条件を含めた計 7 段階の高さ条件を用意した。各条件について 5 回の試行を行い、成功率を算出した。各枚数条件における対象物の様子を Fig. 3.2 に示す。

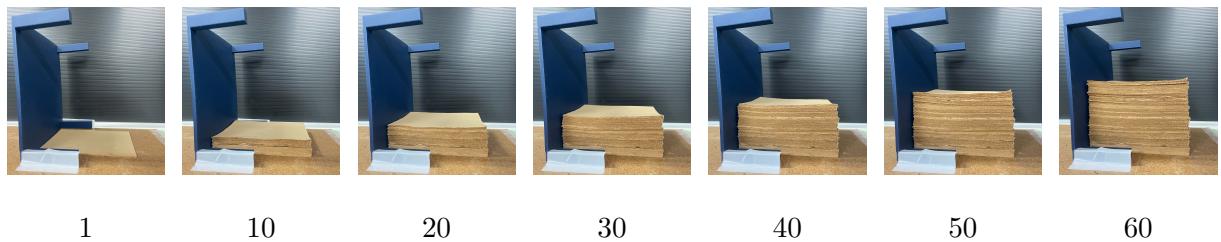


Fig 3.2. Representative images of the Kim towel at each sheet count (1, 10, 20, 30, 40, 50, 60).

さらに、経年変化やパーツ交換によるハードウェアの変動を想定し、指先のソフトフィンガーの長さを変更した条件での評価も行った。具体的には、教示時と同一の長さの条件 (Fig. 3.3) に加え、指先位置を 30mm 短縮した条件 (Fig. 3.4) においても検証を行った。

以下の表に、各条件での成功率を示す。Table3.1 は指先を教示データと同じ長さにした場合、Table3.2 は指先を 30mm 短くした場合の成功率である。

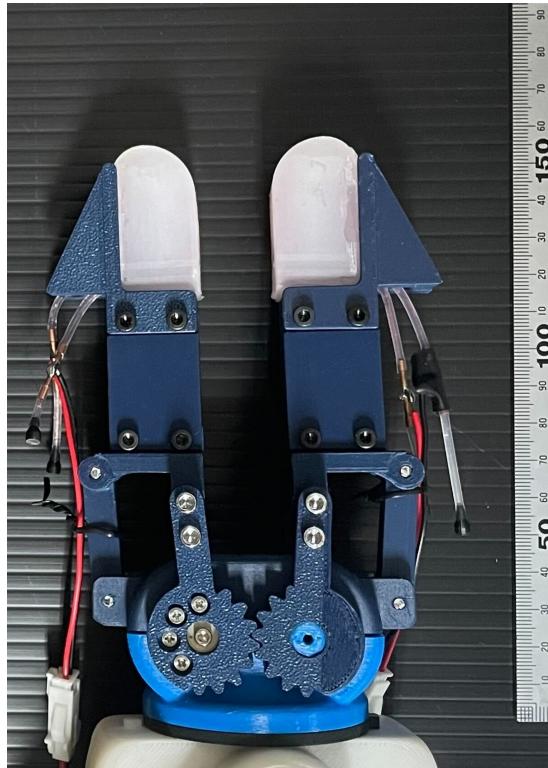


Fig 3.3. Fingers extended by 30mm (same as demonstration)

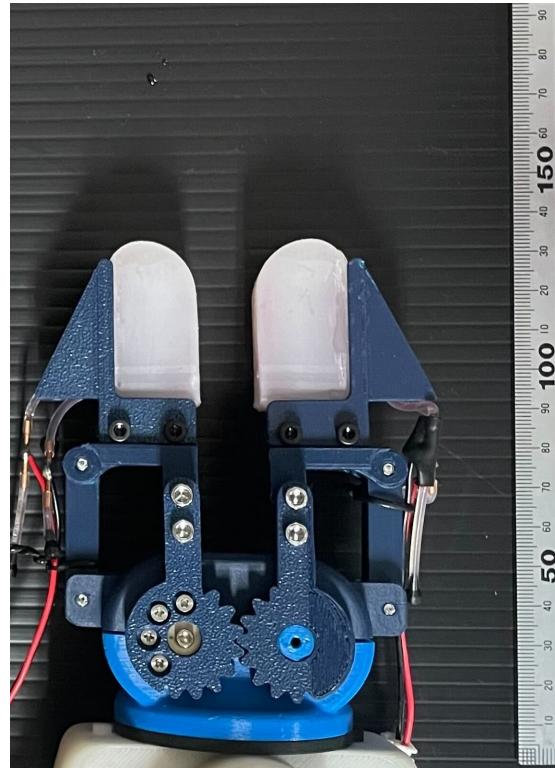


Fig 3.4. Fingers extended by 0mm

Table 3.1. Success rate with fingers extended by 30mm (same as demonstration data)

sheets	sensor_on	sensor_off
60	100.0(5/5)	20.0(1/5)
50	100.0(5/5)	60.0(3/5)
40	100.0(5/5)	0.0(0/5)
30	100.0(5/5)	100.0(5/5)
20	100.0(5/5)	100.0(5/5)
10	100.0(5/5)	100.0(5/5)
1	100.0(5/5)	20.0(1/5)

Table 3.2. Success rate with fingers extended by 0mm (different from demonstration data)

sheets	sensor_on	sensor_off
60	100.0(5/5)	100.0(5/5)
50	100.0(5/5)	80.0(4/5)
40	100.0(5/5)	100.0(5/5)
30	100.0(5/5)	100.0(5/5)
20	80.0(4/5)	0.0(0/5)
10	100.0(5/5)	0.0(0/5)
1	0.0(0/5)	0.0(0/5)

キムタオル把持タスクの実験時のロボットの動作遷移

FigB.1 および Fig B.2 において、同じ記号（#1～#8）が付された画像は、側面カメラおよび上面カメラによって同時に撮影されたフレームに対応している。

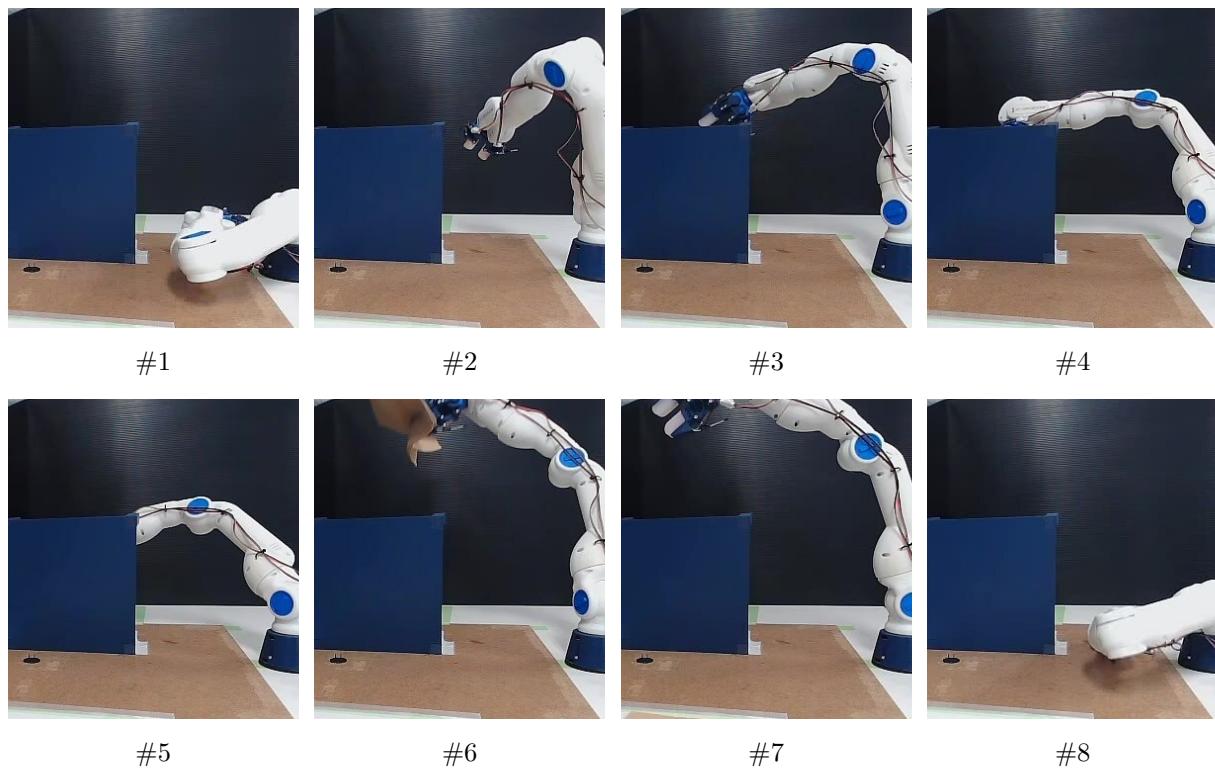


Fig B.1. Sequence of side-view camera images in time order.

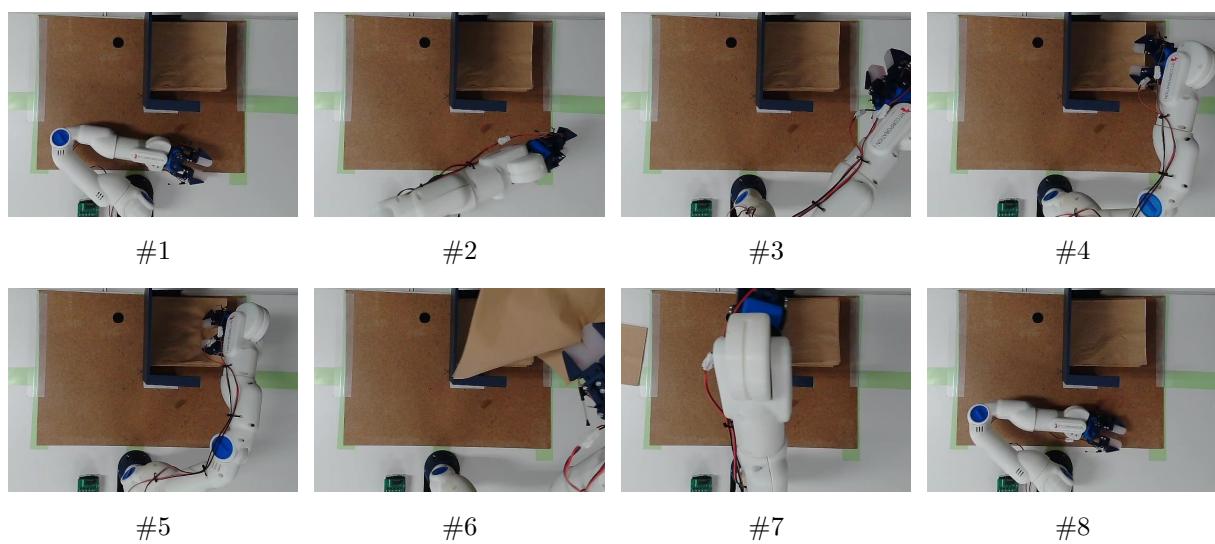


Fig B.2. Sequence of top-view camera images in time order.

3.2 重力補償を導入した操作しやすいリーダーアームによって容易になる折り紙タスク

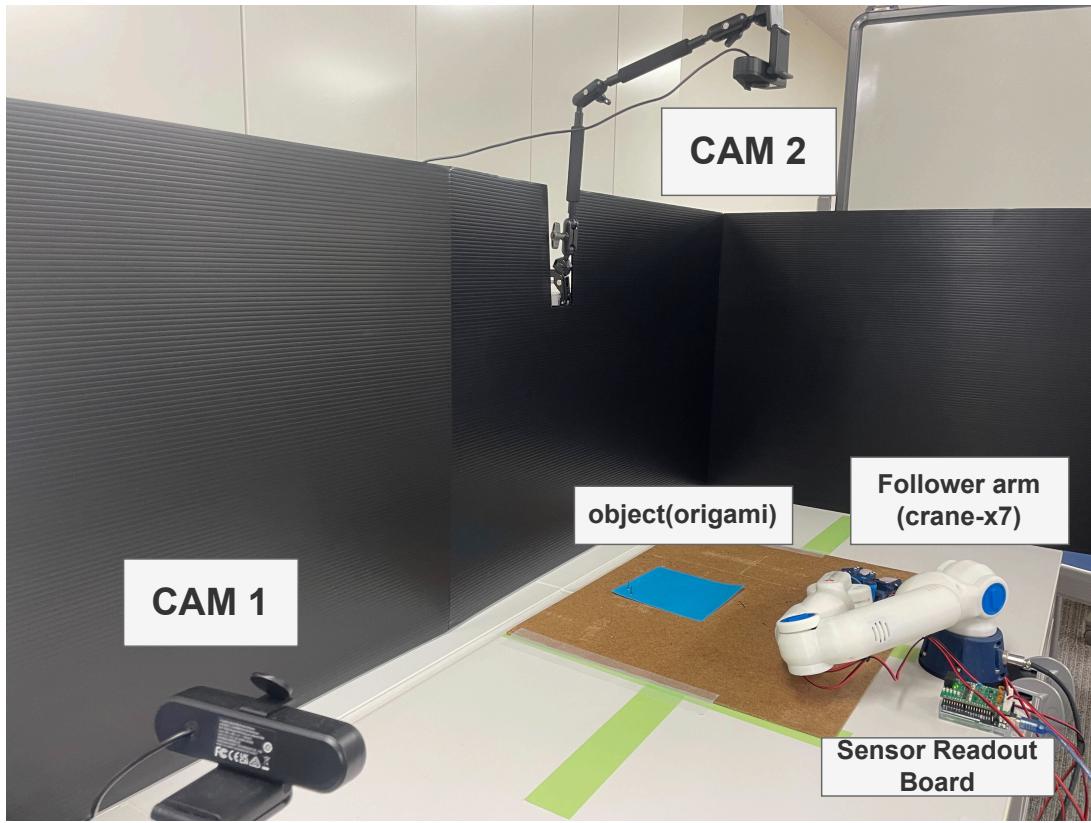
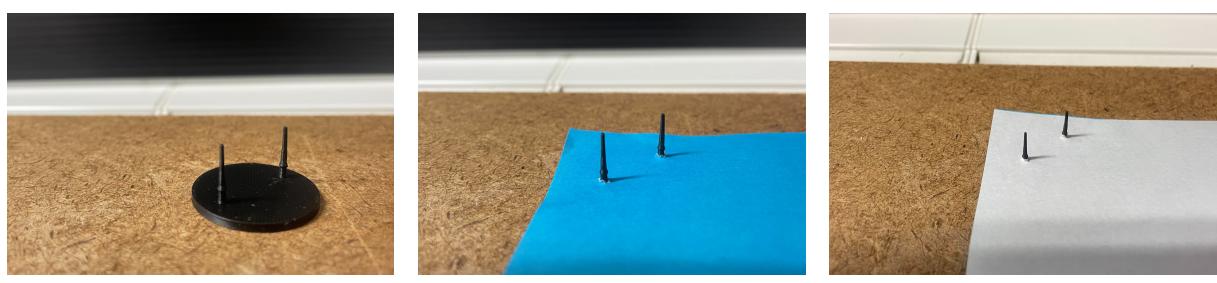


Fig B.3. Experiment setup (layout, observation cameras, and equipment configuration)

本節では、重力補償制御の有用性を検証するため、ロボットアームと人間が協働して行う折り紙タスクを実施した。折り紙のような柔軟物を扱う作業では、正確な折り目をつけるために両手（あるいは複数のマニピュレータ）による操作が求められる場合が多い。本実験では、単腕ロボットアームでこのタスクを遂行するため、人間が環境側に介入して紙を固定する補助を行う設定とした。この際、操作者は「リーダーアームの操作」と「紙の固定補助」という2つの役割を1人で担う必要がある。そのため、補助動作中はリーダーアームから手を離す必要が生じるが、重力補償が適用されていれば、アームはその姿勢を維持し続けることができる。



Jig only

Jig with 1 sheet

Jig with 2 sheets folded

Fig B.4. Photographs of jig: from left to right, jig alone, jig with 1 sheet of paper attached, jig with 2 sheets of paper attached.

3.2.1 タスクの教示，学習条件

実験セットアップを Fig. 3.5 に示す。単腕での操作を補助するため、折り紙の片側を固定する専用の治具 (Fig. 3.6) を作製した。タスクの目標は、机上の治具に固定された折り紙を持ちし、谷折りにして折り目をつけることである。治具には固定用のピンが設けられており、ロボットが紙を折り返したタイミングで、人間が紙をピンに差し込み固定を行う。

教示データ収集は計 10 エピソード行った。各エピソードの開始時、折り紙の配置位置は固定せず、操作者が治具に対して概略の位置に配置した。

教示の具体的な手順は以下の通りである (Fig. C.1 参照)。

把持・折り動作: 操作者はリーダーアームを操作し、ソフトフィンガーで紙を持ちして折り返す (#1～#5)。

姿勢維持（重力補償の活用）: ロボットが紙を折り返した状態で、操作者はリーダーアームから手を離す。重力補償により、ロボットは紙を保持したままの姿勢を維持する。

人間による介入: 操作者は手を使って紙を治具のピンに固定する (#6)。

折り目付け: 再びリーダーアームを操作し、爪部分を使用し折り目を作る動作を行う (#7～#8)。

折り紙タスクの実験時のロボットの動作遷移

折り紙タスクにおけるロボットの動作遷移を以下に示す。

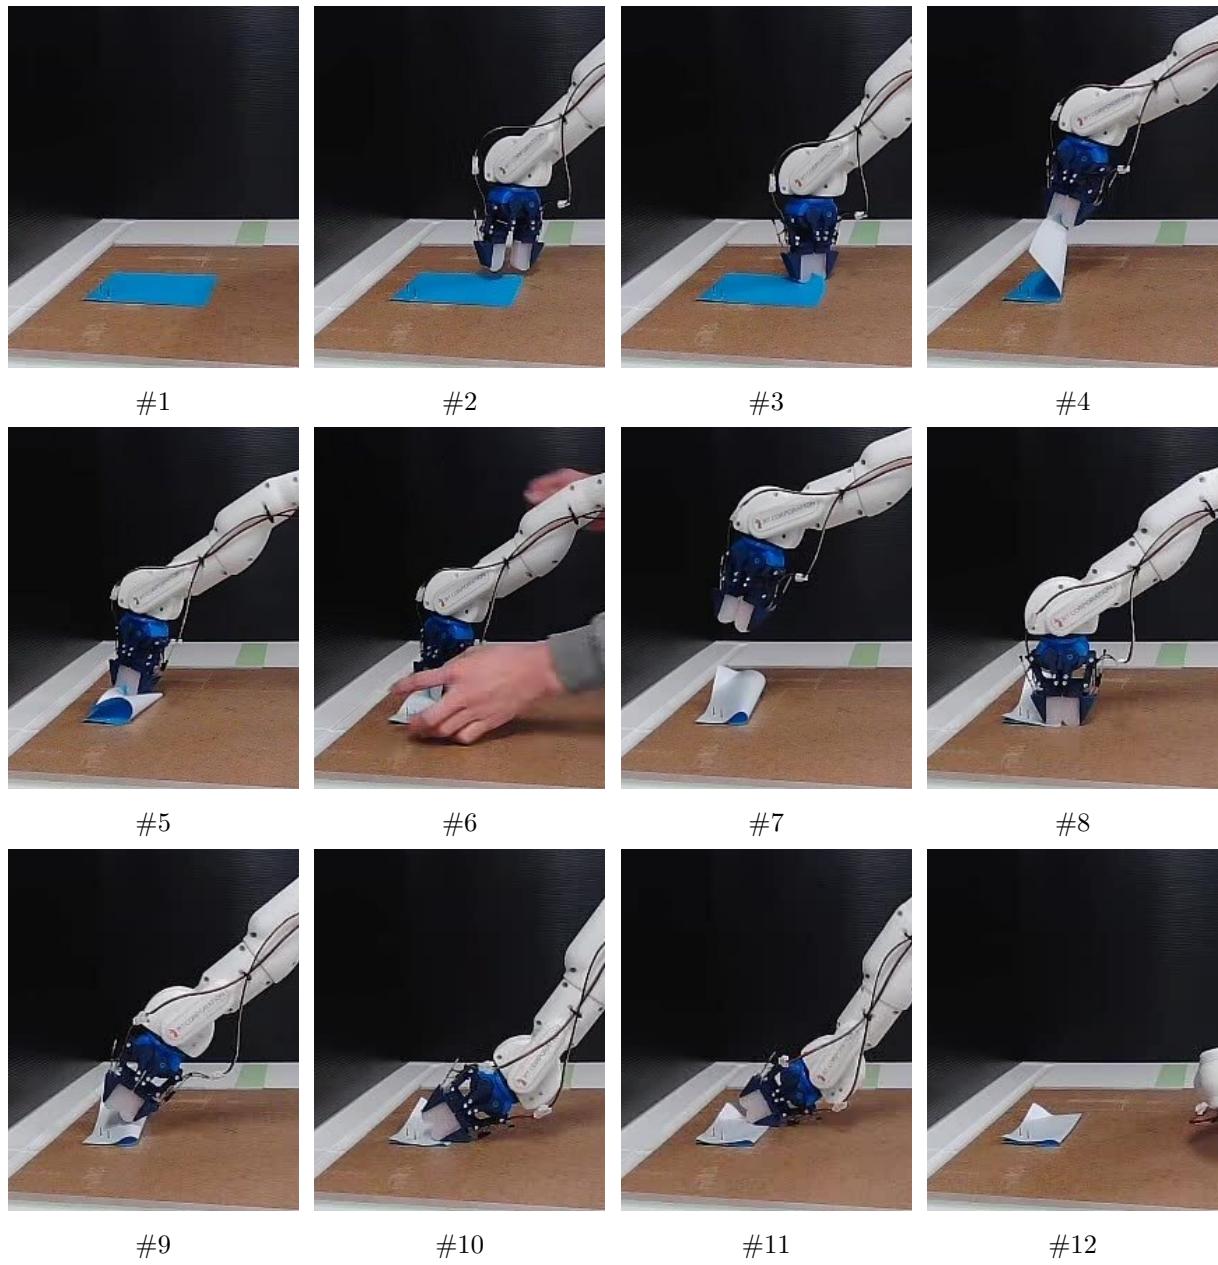


Fig C.1. Sequence of side-view camera images during origami task in time order.

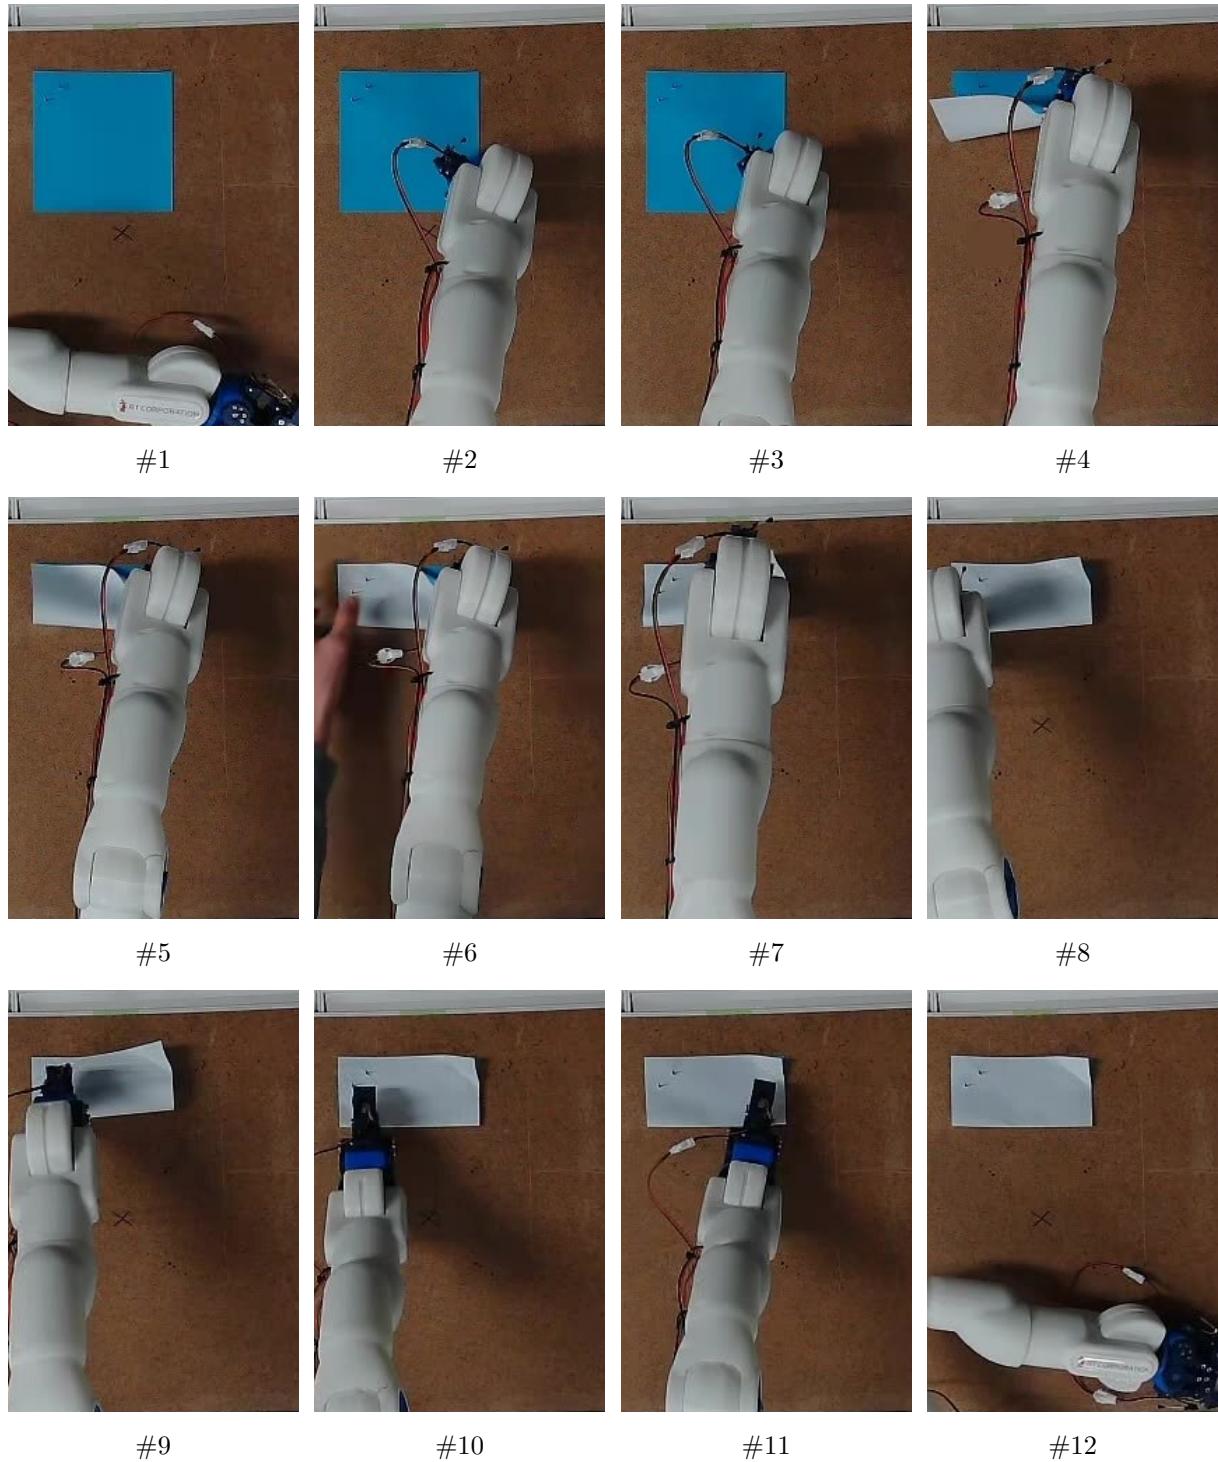


Fig C.2. Sequence of top-view camera images during origami task in time order.

3.2.2 タスクの評価と成功率

タスクの成功条件は、「余分な折り目をつけることなく、教示と同様の方向に紙を折ることができ、かつ外力を加えない状態で折り目が維持されていること」とした。実験の結果、10回の試行のうち9回で成功し、成功率は90%であった。

4 議論

4.1 触覚情報の活用による把持成功率の向上

キムタオルの把持タスクにおいて、触覚情報の有無による学習モデルの比較検討を行った。その結果、教示データと同一の指長さを用いた条件において、触覚ありモデル (Sensor_on) は教示データに含まれない高さ条件であっても 100% の成功率を達成した。一方で、触覚なしモデル (Sensor_off) では、把持高さが教示データと異なる場合に成功率が著しく低下したほか、教示データと同一の高さであっても一部で成功率の低下が確認された。

Sensor_off 条件において成功率の低下およびばらつきが生じた主要因として、視覚情報のみに依存した高さ推定の限界が挙げられる。本実験環境では、側面カメラは障害物によるオクルージョンが発生し、上面カメラは深度情報を持たない RGB カメラである。そのため、積層されたキムタオルの高さ変化を画像特徴の変化としてのみ捉える必要があるが、照明条件の変動やわずかな位置ずれにより、その特徴量は不安定となる。実際、Sensor_off 条件における失敗エピソードを確認すると、アームが対象の手前で停止する、あるいは過剰に押し込むといった動作が確認された。成功しているエピソードに関しては、偶発的に画像特徴による高さ推定が成功したか、あるいは指の柔軟性が推定誤差を吸収した結果であると推察される。

これに対し、Sensor_on 条件では、視覚情報による位置推定に誤差が含まれる場合でも、高い成功率を維持した。これは、ソフトフィンガーが対象に接触した際の抵抗値変化をトリガーとして把持動作が調整されているためであることが示唆される。すなわち、視覚情報の不確実性を触覚情報が補完することで、環境変動（高さの変化）に対するロバスト性が向上したと結論付けられる。

次に、指の長さを変更した条件（教示時より短い指）での結果について考察する。この条件においても、触覚ありモデルは概ね高い成功率を維持した。しかし、対象物が「1枚（高さ最小）」の場合においては、触覚ありモデルであっても把持に失敗（成功率 0%）した。この原因是、教示データに含まれる関節角度の分布にあると考えられる。教示データには、指が短くなった分だけアームを深く下ろすような動作データは含まれていない。本手法で用いた ACT アーキテクチャは、触覚情報を利用することで接触時の微調整（局所的な適応）は可能であるが、教示された関節角度の分布から大きく逸脱するような大域的な軌道修正（教示時よりもさらに深くアームを下げる動作）までは生成できない。したがって、1枚の条件での失敗は、学習ベースの手法における汎化性能の限界を示していると言える。

一方で、触覚なしモデルにおいて、指を短くした条件の方がむしろ成功する場合が見られた（多めの枚数時）。これは、教示データと同一の指長さでは「深く掴みに行き過ぎていた（過剰な押し込みがあった）」動作が、指が短くなったことで偶然適切な深さになったためと考えられる。

以上の結果より、触覚情報の統合は、物体の柔らかさや接触判定といった視覚のみでは捉えきれないコンテクスト情報を補完し、タスクの成功率向上に大きく寄与することが示された。ただし、その適応能力は教示データの運動学的範囲に依存し、物理的な接触のみでは補いきれない幾何学的な制約が存在することも確認された。

4.2 重力補償制御によるタスクの幅の拡大

本研究で導入した重力補償制御下で、アームの重量を感じさせない直感的な操作感が実現した。さらに特筆すべき点は、アームを任意の位置で静止させ、その姿勢を維持できることである。これにより、操作者が一時的にアームから手を離し、環境側（対象物や治具）への介入を行うといった協働作業が可能となった。

この利点は、実施した折り紙タスクにおいて顕著に確認された。本タスクでは、「アームによる折り動作」と「人間による治具への固定補助」を交互に行う必要がある。重力補償機能により、操作者はロボットの操作を中断してもその作業状態を維持できるため、一人での教示の幅を大きく拡大できた。

本実験では筋電位計測による作業負荷計測やアンケート手法、教示にかかる時間比較などの定量的な負荷評価は行っていないものの、実機運用を通じて、重力補償の導入が教示者の主観的負担を大幅に軽減し、かつ一人で教示可能なタスクの幅を拡大することを確認した。

5 結言

本研究では、接触を伴う物体操作タスクにおいて、視覚情報のみでは捉えきれない環境変動への適応と、複雑なタスクにおける高品質な教示データ収集の実現を目的とし、イオン液体センサ内蔵ソフトフィンガーを用いた模倣学習手法および、重力補償制御を実装したテレオペレーションシステムを提案した。

第一に、ソフトフィンガーの柔軟性と触覚センシングを統合した模倣学習の有効性について検証した。キムタオル把持タスクを用いた評価実験の結果、提案手法は視覚的なオクルージョンがあっても、接触時のセンサ応答に基づき把持動作を適応的に調整可能であることを示した。特に、視覚のみでは高さ推定が困難な未知の積層枚数条件において、触覚統合モデルが高い成功率を維持したことは、ソフトフィンガーによる形状適合性と内部流路の変形計測が、タスクのロバスト性向上に寄与することを実証するものである。一方で、学習された方策の汎化能力は教示データの運動学的範囲に依存しており、教示時の可動域を大きく逸脱するような幾何学的制約（極端に低い位置での把持など）に対しては、触覚情報のみでの補正に限界があることも確認された。

第二に、重力補償制御を導入した教示システムの有用性について検証した。7自由度ロボットアームを用いたテレオペレーションにおいて、重力補償による操作支援は、アームの自重による操作者の身体的・認知的負荷を軽減するだけでなく、教示作業の中止と再開をシームレスに行うことを可能にした。折り紙タスクの実機実験では、この特性を活かし、操作者がロボット操作と治具への固定補助を交互に行う教示作業を円滑に遂行できることを確認した。

今後の展望として、本研究で得られた知見を双腕マニピュレーションへと拡張することが挙げられる。双腕作業においては、片腕で対象を保持しつつ他方の腕で操作を行うといった、より複雑な協調動作が求められるため、重力補償による操作支援の重要性はさらに増大すると考えられる。また、触覚情報を活用することで、腕が2本になることにより必然的に増えるセルフオクルージョンの問題を緩和し、より精密な操作が可能になると考えられる。

謝　　辞

本研究の実施や論文の執筆にあたり、多くの方々にご指導とご協力をいただきましたことに、心より感謝申し上げます。京都大学大学院工学研究科機械理工学専攻の細田耕教授、川節拓実講師には、熱心にご指導いただきました。研究室秘書の堀祐子さんには、研究に関わることだけでなく、研究室での生活や様々な場面でお世話になりました。また、研究室の先輩方には様々な助言や激励の言葉をいただき、特に辻大樹さんには、研究に関することについて何度も相談に乗ってくださいました。慣れない環境で初めて研究に取り掛かり、不安なこともたくさんありましたが、研究室同期で話す時間が何より励みになりました。

本研究は以上の方々のサポートがなければ終えることは出来ませんでした。この場を借りて深く感謝申し上げます。

令和8年2月 小森 文雄

付 錄

使用機材の諸元

本研究の実験システムを構成するロボットアームおよびカメラの主要な仕様を、表 A.1 にまとめる。

Table A.1. 実験システムのハードウェア構成

項目	仕様
1. ロボットアーム	
型番	RT-CRANE-X7
自由度	7
作業有効範囲	500 mm
可搬重量	約 0.5 kg
エンドエフェクタ	両開きハンド 1
外形寸法	130 × 100 × 708 mm (固定用金具 5mm を含む)
本体重量	約 1.5 kg
搭載アクチュエータ	ROBOTIS 製 XM540-W270-R, XM430-W350-R
2. RGB カメラ	
型番	EMEET SmartCam C960
使用台数	2 台
入力解像度	640 × 480 pixel
フレームレート	30 fps
画角 (FOV)	90°